PREDICCIÓN DE LA RADIACIÓN SOLAR

RAUL BOGDAN
MARIAN SANTA

ÍNDICE

INTRODUCCIÓN 3

1) Análisis exploratorio de datos 4

2) Relative Absolute Error(RAE) 6

3) Preproceso 7

3.1) Mejor método de imputación/escalado 7

3.2) Evaluación de métodos SIN ajuste de hiperparámetros 10

3.3) Evaluación de métodos CON ajuste de hiperparámetros 21

3.4) Método Ensembles 30

4) Modelo Final 38

5) Ajuste de hiperparámetros con hyperband 41

INTRODUCCIÓN

Las fuentes de energía renovable, como la solar o la eólica, ofrecen muchas ventajas ambientales sobre los combustibles fósiles para la generación de electricidad, pero la energía que producen fluctúa con las condiciones climáticas cambiantes. Las empresas de servicios eléctricos necesitan pronósticos precisos de la producción de energía para tener disponible el equilibrio adecuado de combustibles fósiles y renovables. Los errores en el pronóstico podrían generar grandes gastos para la empresa de servicios públicos debido al consumo excesivo de combustible o compras de emergencia de electricidad a las empresas vecinas. Los pronósticos de energía generalmente se derivan de modelos numéricos de predicción del clima, pero las técnicas estadísticas y de aprendizaje automático se utilizan cada vez más junto con los modelos numéricos para producir pronósticos más precisos.

El objetivo de este concurso es descubrir qué técnicas estadísticas y de machine learning proporcionan las mejores predicciones a corto plazo de la producción de energía solar. Se predecirá el total de energía solar entrante diaria en 98 sitios de Oklahoma Mesonet.

Hay 15 variables, predichas para 5 momentos del día siguiente lo que equivale a 75 atributos de entrada. En cuanto a las instancias tenemos que son 4380. En cuanto a las variables:

- **1: apcp_sfc**. Precipitación acumulada en 3 horas en la superficie. Mide en kg/m^2.
- **2: dlwrf_sfc.** Promedio del flujo radiativo de onda larga descendente en la superficie. Mide en W/m^2.
- **3: dswrf_sfc**. Promedio del flujo radiativo de onda corta descendente en la superficie. Mide en W/m^2.
- **4: pres_msl**. Presión del aire al nivel medio del mar. Mide en Pa.
- **5: pwat_eatm**. Agua precipitable en toda la profundidad de la atmósfera(representa la cantidad de agua potencial para ser precipitable ya sea lluvia, nieve, granizo,etc…). Mide en Kg/m^2.
- **6: spfh_2m.** Humedad específica a 2 metros del suelo. Mide en Kg.
- **7: tcdc_eatm.** Cobertura total de nubes en toda la profundidad de la atmósfera. Mide en %.
- **8: tcolc_eatm.** Condensado total integrado en la columna en toda la atmósfera. Mide en Kg/m^2.
- **9: tmax_2m.** Temperatura máxima durante las últimas 3 horas a 2 metros sobre el suelo. Mide en K(kelvin).
- **10: tmin_2m**. Temperatura mínima durante las últimas 3 horas a 2 metros sobre el suelo. Mide en K(kelvin).
- **11: tmp_2m.** Temperatura actual a 2 m sobre el suelo. Mide en K(kelvin).

- **12: tmp_sfc.** Temperatura de la superficie. Mide en K(kelvin).
- **13: ulwrf_sfc.** Radiación de onda larga ascendente en la superficie. Mide en W/m^2.
- **14: ulwrf_tatm.** Radiación de onda larga ascendente en la parte superior de la atmósfera. Mide en W/m^2.
- **15: uswrf_sfc.** Radiación ascendente de onda corta en la superficie. Mide en W/m^2.

*** A pesar de que las variables originales representan lo indicado anteriormente, los datos han sido modificados y por ende algunos no corresponden con los valores "esperados", por ejemplo, si la variable original es numérica al haber sido cambiada puede tener valores no numéricos como carácteres o factores.

Fuente: https://www.kaggle.com/c/ams-2014-solar-energy-prediction-contest/data

Primero procedemos a leer los datos.

1) Análisis exploratorio de datos

En cuanto a los datos observamos que hay 4380 filas y 76 columnas(75 si contamos los atributos que serán los independientes ya que el atributo restante es el dependiente que se intentará explicar con ayuda de las otras variables).

Hay tres tipos de datos: carácteres(constituyen 3 columnas), factores(constituyen 34 columnas) y numéricos(constituyen 39 columnas).

En lo referente a las variables numéricas, destaca que una gran parte presenta asimetría hacia la derecha.

¿Hay missing values? ¿Si es así, cual es la proporción de estos respecto al total?

Se puede observar el número de datos faltantes por cada variable. LLama la atención la variable pres_ms2_1, la cual indica la presión del aire respecto al nivel del mar, ya que el porcentaje de missing values es más del 90% de las observaciones(es de ≈ 94%).

En total hay 18571 datos faltantes.

En conclusión, obtenemos que hay 18571 datos faltantes de 332880. Lo que constituye ≈ el 5.5% respecto al total del conjunto de datos.

Atributos constantes

```
# Comprobamos a que atributos corresponden los valores únicos.
which(unicos==1)
```

```
      ## tcdc_ea4_1 tcolc_e3_1 tmin_2m5_1 tmp_2m_2_1
##         34          38          50          52
```

Las columnas 34, 38, 50 y 52 son las que tienen valores constantes.

Distribución de la variable respuesta a través del tiempo

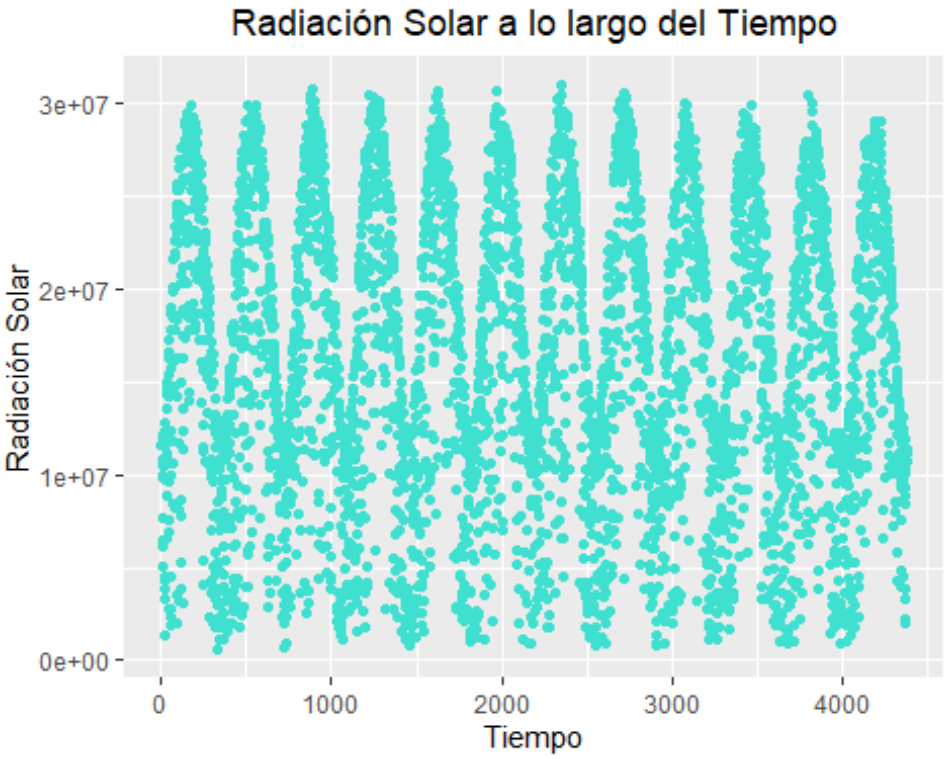

En forma de GIF:

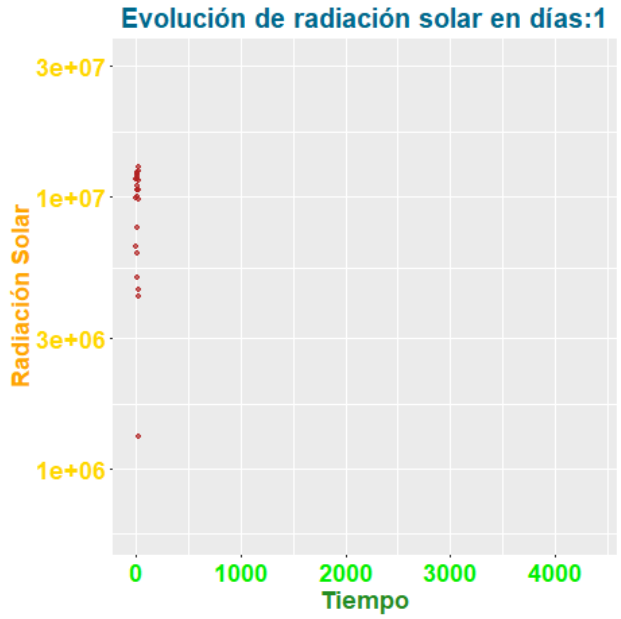

Como observamos en la imagen la distribución de la radiación solar a lo largo del tiempo presenta un patrón no lineal, más bien parece un patrón en forma de curvas que se repite a cada cierto periodo de tiempo. Empieza creciendo de forma exponencial, hasta llegar a un máximo y luego desciende de manera exponencial y luego vuelve a crecer. Tiene forma cóncava, como si fuera una cordillera/montañas. Por tanto vemos que como presenta un patrón característico, y vamos a usar diferentes modelos de aprendizaje automático para entrenarlos y ver si son capaces de predecir valores futuros. Finalmente, los compararemos para ver cual predice mejor su comportamiento y seleccionaremos el mejor modelo, que será aquel que tenga un menor error.

Preproceso

```
# Primero, convertimos los "characters" a factores

j<-1

for(j in 1:ncol(datos)){
  if(is.character(datos[,j])){
    datos[,j]<-as.factor(datos[,j])
  }
  else{}
  j<-j+1
}
```

2) Relative Absolute Error(RAE)

El método RAE, es una métrica para evaluar la capacidad predictiva de un modelo. Es un cociente entre los residuos(la diferencia entre el valor predicho y el real) y la diferencia entre el valor real y su media. La parte del numerador nos indica la distancia de los valores predichos a los valores reales mientras que el denominador es un indicador de centralidad, es decir, nos indica lo que se alejan las observaciones respecto a su media(modelo básico).

Por tanto, el error RAE es una medida relativa, al comparar un modelo de regresión(que indica cuanto se alejan los valores reales de los predichos en media) con un modelo normal(indica cuanto se alejan los valores reales de la media).

Si el modelo realiza bien las predicciones, entonces el numerador será pequeño(si es 0 entonces es que predice perfectamente) y al hacer el cociente el error también será pequeño. En cambio si el numerador es grande, eso indica que el modelo no ha sido capaz de captar y entrenar correctamente y al hacer el cociente el error es más grande. Si el modelo es peor que el modelo trivial/básico entonces el error es mayor que 1(es decir, que el numerador es mayor que el denominador, entonces el modelo es muy malo).

Tiene la siguiente fórmula:

$$\frac{\sum_{i=1}^{n}|y_i - \hat{y}_i|}{\sum_{i=1}^{n}|y_i - \bar{y}|}$$

Toma valores entre 0 e infinito. Si el cociente es próximo a 0 indica que el modelo predictivo es bueno, ya que cuanto menor sea el numerador, menor distancia habrá entre los valores predichos a los reales.

3) Preproceso

3.1) Mejor método de imputación/escalado

Antes de empezar a crear modelos, como hemos visto que hay valores faltantes hay que hacer un previo proceso de imputación(para no perder la "potencial" información que aporten los datos faltantes) y también de escalado(ya que los datos están medidos en diferentes unidades).

```
# Creamos nuestra tarea de regresión

my_task<-as_task_regr(datos,target = "salida")

# Dividimos en entrenamiento y test
# En entrenamiento de los 12 años, cogemos 9, de los cuales 6 se usaran
para entrenar y 3 para validar mientras que los últimos 3 años se dejan
para test

trainvalid<-datos[1:(9*365),]
test<-datos[(9*365+1):(12*365),]

# Validamos el modelo
# Fijamos una semilla(para reproducibilidad del modelo)
set.seed(100365469)

trainvalid_partition<-rsmp("custom")
trainvalid_partition$instantiate(my_task,train=list(1:(6*365)),test=(list
((6*365+1):nrow(trainvalid))))

# Definimos el learner(método de aprendizaje), en este caso usaremos para
evaluar el método KNN del paquete "kknn".

learner_name <- "regr.kknn"
knn_learner <- lrn(learner_name)

# Definimos secuencia con diferentes formas de imputación como con la
media, mediana, histograma o muestra y escalado normal o por rango.

# Imputación para valores numéricos.
```

```
imputacion<-c("imputemean","imputehist","imputemedian","imputesample")

# Imputación para categóricos, usaremos "imputemode".
# Escalado

escalado<-c("scale","scalerange")
# Definimos un vector de errores, donde se guardan los errores de las
distintas combinaciones de imputar/escalar y escogeremos el que sea más
óptimo(menor error).
errores_pre<-c()

for(i in 1:length(imputacion)) {
for(j in 1:length(escalado)) {
  preproc<-po(imputacion[i]) %>>%
    po("imputemode") %>>%
    po("removeconstants") %>>%
    po(escalado[j])
  graph<-preproc %>>%
       po(knn_learner)
  impute_knn<-as_learner(graph)

# Definimos la forma de evaluación

  set.seed(100365469)
  res_desc<-rsmp("custom")

res_desc$instantiate(my_task,train=list(1:(6*365)),test=(list((6*365+1):n
row(trainvalid))))

# Entrenamos el modelo
  knn_resample<-resample(task=my_task,
                         learner=impute_knn,
                         resampling = res_desc)

# Calculamos el error
  knn_error<-knn_resample$aggregate(msr("regr.rae"))
  errores_pre<-c(errores_pre,knn_error)
  }
}

# Probamos con el imputador multivariante

errores_pre_m<-c()

for(j in 1:length(escalado)) {
  preproc<-po("imputelearner",lrn("regr.rpart")) %>>%
    po("imputemode") %>>%
    po("removeconstants") %>>%
    po(escalado[j])
```

```
    graph<-preproc %>>%
       po(knn_learner)

    impute_mult<-as_learner(graph)

# Definimos la forma de evaluación

  set.seed(100365469)
  res_desc<-rsmp("custom")

res_desc$instantiate(my_task,train=list(1:(6*365)),test=(list((6*365+1):n
row(trainvalid))))

# Entrenamos el modelo
  mult_resample<-resample(task=my_task,
                          learner=impute_mult,
                          resampling = res_desc)

# Calculamos el error
  mult_error<-mult_resample$aggregate(msr("regr.rae"))
  errores_pre_m<-c(errores_pre_m,mult_error)
  }
```

En la siguiente tabla vemos el resumen de lo diferentes métodos analizados para el preproceso:

Método de Imputación	Escalado Normal	Escalado Rango
Media	0.3911393	0.3911393
Histograma	0.3920328	0.3920328
Mediana	0.3903049	0.3903049
Sample	0.3873413	0.3873413
Multivariante	0.3772216	0.3772216

```
## El mejor método de imputación/escalado es: 9 que coincide con el
modelo: imputación:multivariante/moda,escalado:normal
```

El mejor método de imputación/escalado es con multivariante/moda y escalado normal. Aunque el segundo menor error es el obtenido con la imputación por mediana y escalado normal(aunque el imputador muestra aleatoria[sample] también da un error parecido). Algunos modelos funcionan mejor con escalado multivariante y

otros con otros métodos como por ejemplo sample/mediana por tanto se aplicará el imputador que menor error consiga para cada determinado modelo(que ha sido comprobado y comparado con anterioridad a hacer los modelos finales que están representados con el código).

3.2) Evaluación de métodos SIN ajuste de hiperparámetros

Para empezar, construiremos varios modelos de regresión pero sin ajustar sus hiper-parámetros y evaluaremos su rendimiento. Posteriormente construiremos modelos ajustamos sus hiper-parámetros y los compararemos con sus respectivos modelos para evaluar si su rendimiento mejora o no en base a los hiper-parámetros elegidos.

Metodología

En principio vamos a crear 6 modelos de regresión: un modelo de regresión lineal múltiple, un modelo de árboles(con rpart), un modelo de regresión con el método knn, un modelo de regresión con svm con el kernel lineal y otro con el kernel radial y por último un modelo de regresión con el método cubist.

Primero incluimos los datos al modelo. Después convertimos los caracteres a factores .Cada learner/método de aprendizaje anterior mencionado trabaja con un tipo de datos(algunos permiten categóricos, otros no) y por tanto se haran los ajustes necesarios en los datos para poder llevar a cabo el modelo. Si el modelo no trabaja con factores se convertirán a enteros, si no trabaja con factores nominales se convertirán a dummies. Para cada modelo ha sido probado varios métodos de preprocesos y se ha seleccionado finalmente el que mejores resultados ha dado.

Después se llevará a cabo el preproceso, donde se le imputarán los valores faltantes, se escalarán los datos y se eliminarán las constantes.

Para entrenar los modelos, usaremos 9 años de los 12 totales. De estos 9 años los 6 primeros(van en orden cronológico) se usarán para entrenar el modelo y se evaluará al modelo con los 3 años siguientes y así con todos los modelos. Finalmente se escogerá el modelo que tenga un menor error(calculado con el método RAE).

En esta primera parte se entrenarán los modelos sin ajuste de hiper-parámetros y después se volverán a crear los modelos, ajustando los hiper-parámetros más importantes para poder comparar y ver si hay diferencias.

Para el ajuste de hiper-parámetros se usarán 2 métodos: grid-search y random-search.

A continuación se crearán 2 modelos de ensembles con y sin ajuste de hiper-parámetros(random forest: ranger y gradient boosting: xgboost).

Por último se creará un modelo final que se usará para realizar predicciones. Se seleccionará el mejor método para crear este modelo final y se usarán todos los datos,

es decir, se usarán los primeros 9 años para entrenar y luego los 3 últimos para el test. Previamente se hará una estimación del modelo.

Modelo Regresión Lineal

Primero creamos un modelo de regresión lineal múltiple, donde la variable dependiente es "salida" y el resto de las variables son las predictoras. Usaremos el learner lm.

```
# Definimos el learner
lm_lrn<-lrn("regr.lm")
lm_lrn$feature_types
```

```
      ## [1] "logical"   "integer"   "numeric"   "factor"    "character"
```

```
# Este learner trabaja con valores lógicos,enteros,numéricos,factores y
carácteres.

# Leemos los datos

datos<-readRDS("disp_38.rds")

# Primero pasamos los carácteres a factores

j<-1

for(j in 1:ncol(datos)){
  if(is.character(datos[,j])){
    datos[,j]<-as.factor(datos[,j])
  }
  else{}
  j<-j+1
}

# El método LM no trabaja con variables ordinales así que los convertimos
a enteros

k<-1

for(k in 1:ncol(datos)){
  if(is.ordered(datos[,k])){
    datos[,k]<-as.integer(datos[,k])
  }
  else{}
  k<-k+1
}


# Definimos la tarea
my_task<-as_task_regr(datos,target="salida")
```

```
# Preproceso
# Los modelos de Regresión Lineal no admite los "missings values" así que
hay que llevar a cabo un método de imputación primero. Así mismo también
escalaremos.

 preproceso_lm<- po("removeconstants") %>>%
 po("imputelearner",lrn("regr.rpart"))%>>%
 po("imputemode") %>>%
 po("scale")

# Unimos con el learner

 graph_lm<-preproceso_lm %>>% lm_lrn
 graph_learner_lm<-as_learner(graph_lm)

# Estrategia de validación, en este caso es personalizada(con los
primeros 6 años entrenamos y los 3 siguientes se hace la validación)
 set.seed(100365469)

 trainvalid<-datos[1:(9*365),]
 test<-datos[(9*365+1):(12*365),]

 res_desc_lm<-rsmp("custom")

res_desc_lm$instantiate(my_task,train=list(1:(6*365)),test=(list((6*365+1
):nrow(trainvalid))))

# Entrenamos el modelo y validamos

 lm_resample<-resample(my_task,graph_learner_lm,res_desc_lm,store_models
= TRUE)

      # Definimos el criterio de calcular el error
 measure<-msr("regr.rae")

# Calculamos el error
 error_lm<-lm_resample$aggregate(measure)

      ## El error del modelo de regresión lineal es: 0.3179911
```

Modelo Rpart

El segundo modelo, es de árboles y lo construiremos con el learner rpart.

```
      # Definimos el learner
rpart_lrn<-lrn("regr.rpart")
rpart_lrn$feature_types

      ## [1] "logical" "integer" "numeric" "factor"  "ordered"
```

```
      # Este learner trabaja con valores lógicos, enteros, numéricos,
factores y categóricos ordinales.

      datos<-readRDS("disp_38.rds")

# Como rpart no trabaja con characteres, los convertimos a factores.
# Convertimos los "characters" a factores

j<-1

for(j in 1:ncol(datos)){
  if(is.character(datos[,j])){
    datos[,j]<-as.factor(datos[,j])
  }
  else{}
  j<-j+1
}

# Definimos la tarea
my_task<-as_task_regr(datos,target="salida")

# Preproceso
# Como hay valores faltantes vamos a hacer imputación para no desechar la
información que pueden porporcionar otras columnas. También escalamos
para centrar los datos

 preproceso_rpart<-po("removeconstants") %>>%
 po("imputemedian")%>>%
 po("imputemode") %>>%
 po("scale")
# Unimos con el learner

 graph_rpart<-preproceso_rpart %>>% rpart_lrn
 graph_learner_rpart<-as_learner(graph_rpart)

      # Estrategia de validación
 set.seed(100365469)

 trainvalid<-datos[1:(9*365),]
 test<-datos[(9*365+1):(12*365),]

 res_desc_rpart<-rsmp("custom")

res_desc_rpart$instantiate(my_task,train=list(1:(6*365)),test=(list((6*36
5+1):nrow(trainvalid))))

# Entrenamos el modelo y validamos

 rpart_resample<-
```

```
resample(task=my_task,learner=graph_learner_rpart,resampling=res_desc_rpa
rt,store_models = TRUE)

      # Calculamos el error

 error_rpart<-rpart_resample$aggregate(measure)

## El error del modelo rpart es: 0.4195004
```

Modelo Vecino Mas Cercano

El tercer modelo será con KNN.

```
      # Definimos el learner
knn_lrn<-lrn("regr.kknn")
knn_lrn$feature_types

      ## [1] "logical" "integer" "numeric" "factor"  "ordered"

      # Este learner trabaja con valores lógicos, enteros, numéricos,
factores y categóricos ordinales.

      datos<-readRDS("disp_38.rds")

# Como KNN no trabaja con characteres, los convertimos a factores
# Convertimos los "characters" a factores

j<-1

for(j in 1:ncol(datos)){
  if(is.character(datos[,j])){
    datos[,j]<-as.factor(datos[,j])
  }
  else{}
  j<-j+1
}

# Definimos la tarea
 my_task<-as_task_regr(datos,target="salida")

# Preproceso
# Imputamos y escalamos

 preproceso_knn<- po("removeconstants") %>>%
 po("imputelearner",lrn("regr.rpart"))%>>%
 po("imputemode") %>>%
 po("scale")

# Unimos con el learner
```

```
 graph_knn<-preproceso_knn %>>% knn_lrn
 graph_learner_knn<-as_learner(graph_knn)

      # Estrategia de validación
 set.seed(100365469)

 trainvalid<-datos[1:(9*365),]
 test<-datos[(9*365+1):(12*365),]

 res_desc_knn<-rsmp("custom")

res_desc_knn$instantiate(my_task,train=list(1:(6*365)),test=(list((6*365+
1):nrow(trainvalid))))

# Entrenamos el modelo y validamos

 knn_resample<-
resample(task=my_task,learner=graph_learner_knn,resampling=res_desc_knn,s
tore_models = TRUE)

# Calculamos el error

 error_knn<-knn_resample$aggregate(measure)

## El error del modelo de Vecino Mas Cercano es: 0.3772216
```

Modelo SVM Lineal

El cuarto modelo será un Suport Vector Machine Lineal.

```
# Definimos el learner

svm_l_lrn<-lrn("regr.svm",kernel="linear")
svm_l_lrn$feature_types

## [1] "logical" "integer" "numeric"

      # Como observamos este learner solo trabaja con datos de tipo
lógico, enteros y numéricos.

      datos<-readRDS("disp_38.rds")

# Como SVM solo trabaja con numéricos y enteros, vamos a convertir los
datos que no lo son.

# Convertimos los "characters" a factores

j<-1

for(j in 1:ncol(datos)){
  if(is.character(datos[,j])){
```

```
    datos[,j]<-as.factor(datos[,j])
  }
  else{}
  j<-j+1
}

# Convertimos las variables categóricas ordinales a enteros

k<-1

for(k in 1:ncol(datos)){
  if(is.ordered(datos[,k])){
    datos[,k]<-as.integer(datos[,k])
  }
  else{}
  k<-k+1
}

# Por último todavía hay variables categóricas/factores dentro de los
datos pero como son nominales(sin orden) hay que convertirlas a dummies.

# Primero identificamos que variables de los datos son factores no
ordinales.

factores<-(sapply(datos, function(datos)
sum(length(which(is.factor(datos))))))
which(factores==TRUE)

      ## apcp_sf1_1 spfh_2m5_1 uswrf_s2_1
##          1         30         72

      # Ahora creamos variables dummies para los factores nominales.

datos <- createDummyFeatures(datos, target = "salida")

# Definimos la tarea
 my_task<-as_task_regr(datos,target="salida")

# Preproceso
# Imputamos y escalamos

 preproceso_svm<- po("removeconstants") %>>%
 po("imputelearner",lrn("regr.rpart"))%>>%
 po("scale")

# Unimos con el learner
 graph_svm<-preproceso_svm%>>% svm_l_lrn
 graph_lrn_svm<-as_learner(graph_svm)
```

```
      # Estrategia de validación
 set.seed(100365469)

 trainvalid<-datos[1:(9*365),]
 test<-datos[(9*365+1):(12*365),]

 res_desc_s<-rsmp("custom")

res_desc_s$instantiate(my_task,train=list(1:(6*365)),test=(list((6*365+1)
:nrow(trainvalid))))


# Entrenamos el modelo y lo validamos

  svm_l_resample<-
resample(task=my_task,learner=graph_lrn_svm,resampling=res_desc_s,store_m
odels = TRUE)

      # Calculamos el error

 error_svm_l<-svm_l_resample$aggregate(measure)

## El error del modelo SVM con kernel lineal es de : 0.3103053
```

Modelo SVM Radial

El quinto modelo, es un Support Vector Machine con kernel gaussiano.

```
      # Definimos el learner
svm_r_lrn<-lrn("regr.svm",kernel="radial")
svm_r_lrn$feature_types

      ## [1] "logical" "integer" "numeric"

      # Igual que antes solo trabaja con datos de tipo lógico, enteros o
numéricos

      datos<-readRDS("disp_38.rds")

 # Como SVM solo trabaja con numéricos y enteros convertimos los datos

# Primero, convertimos los "characters" a factores

j<-1

for(j in 1:ncol(datos)){
  if(is.character(datos[,j])){
    datos[,j]<-as.factor(datos[,j])
  }
  else{}
  j<-j+1
```

```
}

# A continuación, convertimos las variables categóricas ordinales a
enteros

k<-1

for(k in 1:ncol(datos)){
  if(is.ordered(datos[,k])){
    datos[,k]<-as.integer(datos[,k])
  }

  else{}
  k<-k+1

  }


# Ahora creamos variables dummies para los factores nominales.

datos <- createDummyFeatures(datos, target = "salida")
# Definimos la tarea

 my_task<-as_task_regr(datos,target="salida")

# Preproceso
# Imputamos y escalamos

 preproceso_r<- po("removeconstants") %>>%
 po("imputelearner",lrn("regr.rpart"))%>>%
 po("scale")

 # Unimos con el learner

 graph_r<-preproceso_r %>>% svm_r_lrn
 graph_learner_r<-as_learner(graph_r)

      # Estrategia de validación
 set.seed(100365469)

 trainvalid<-datos[1:(9*365),]
 test<-datos[(9*365+1):(12*365),]

 res_desc_r<-rsmp("custom")

res_desc_r$instantiate(my_task,train=list(1:(6*365)),test=(list((6*365+1)
:nrow(trainvalid))))

# Entrenamos el modelo
```

```
 svm_r_resample<-
resample(task=my_task,learner=graph_learner_r,resampling=res_desc_r,store

      # Calculamos el error

 error_svm_r<-svm_r_resample$aggregate(measure)

      ## El error del modelo SVM con kernel gaussiano es: 0.3075657
```

Modelo cubist

El sexto y último modelo será con el método "cubist"(otro método para hacer árboles). Se hacen árboles donde las hojas contienen modelos de regresión lineales. Estos modelos se basan en predictores usados en las separaciones/"splits" anteriores. Se hace una predicción utilizando el modelo de regresión lineal en el nodo terminal del árbol, pero se "suaviza" teniendo en cuenta la predicción del modelo lineal en el nodo anterior del árbol (que también ocurre recursivamente en el árbol). El árbol se convierte en un conjunto de reglas que va desde arriba del árbol hasta abajo.

```
# Definimos el learner
cub_lrn<-lrn("regr.cubist")
cub_lrn$feature_types

      ## [1] "integer"   "numeric"   "character" "factor"    "ordered"

      # Este learner trabaja con enteros, numéricos, carácteres, factores
y categóricas ordinales

      datos<-readRDS("disp_38.rds")

# Convertimos los "characters" a factores

j<-1

for(j in 1:ncol(datos)){
  if(is.character(datos[,j])){
    datos[,j]<-as.factor(datos[,j])
  }
  else{}
  j<-j+1
}

# Definimos la tarea
 my_task<-as_task_regr(datos,target="salida")

# Preproceso
# Imputamos y escalamos

 preproceso_c<-  po("removeconstants") %>>%
 po("imputesample")%>>%
```

```
 po("imputemode") %>>%
 po("scale")

 # Unimos con el learner

 graph_c<-preproceso_c %>>% cub_lrn
 graph_learner_c<-as_learner(graph_c)

      # Estrategia de validación

 set.seed(100365469)

 trainvalid<-datos[1:(9*365),]
 test<-datos[(9*365+1):(12*365),]

 res_desc_c<-rsmp("custom")

res_desc_c$instantiate(my_task,train=list(1:(6*365)),test=(list((6*365+1)
:nrow(trainvalid))))

# Entrenamos el modelo

 cub_resample<-
resample(task=my_task,learner=graph_learner_c,resampling=res_desc_c,store
_models = TRUE)

      # Calculamos el error

 error_cub<-cub_resample$aggregate(measure)

      ## El error del modelo cubist es: 0.3274306
```

De los 6 ajustes anteriores, ¿cuál es el que tiene un menor error?

```
      ## El modelo con el menor error es el 5 que corresponde con el
modelo: Modelo SVM Radial

      ## El modelo con el mayor error es el 2 que corresponde con: Modelo
Rpart
```

Errores Modelos Sin Ajuste Hiper-Parámetros

Modelo Lineal	**Rpart**	**KNN**	**SVM Lineal**	**SVM Radial**	**Modelo Cúbico**
0.3179911	0.4195004	0.3772216	0.3127222	0.3075657	0.3274306

Conclusiones:

Como vemos en la anterior tabla, observamos que el menor error sin ajuste de hyperparámetros lo obtenemos con modelo SVM con kernel gaussiano. Aunque el modelo de regresión lineal, svm lineal o con el método "cubist" también ofrece resultados parecidos y no mucho peores. El modelo con el que peor resultado se obtiene es con rpart de árboles que tiene ≈ 10% más de error seguido de KNN. -A pesar de que el modelo SVM radial es el que nos da menor error, los modelos lineales tampoco lo hacen mal. No hay una clara distinción entre si los modelos lineales vs los no lineales ofrecen mejores resultados.

3.3) Evaluación de métodos CON ajuste de hiperparámetros

Ahora vamos a volver a crear los mismos modelos que antes(excepto cubist) y haremos un proceso de ajuste de hiper-parámetros para posteriormente compararlos con los respectivos modelos anteriores sin ajuste y comparar las diferencias de los rendimientos.

Modelo KNN Con Ajuste Hiper-Parámetros

Para este modelo ajustaremos el número de vecinos ya que es su hiper-parámetro más importante. Lo vamos a hacer con el método de "grid-search", que en un espacio definido, busca valores del hiper-parámetro e ira haciendo diversas combinaciones y se ajustará el que mejor resultado tenga.

```
      datos<-readRDS("disp_38.rds")

# Definimos el learner

knn_lrn_h<-lrn("regr.kknn")

# Como KNN no permite carácteres, los convertimos a factores
# A continuación, convertimos los "characters" a factores

j<-1

for(j in 1:ncol(datos)){
  if(is.character(datos[,j])){
    datos[,j]<-as.factor(datos[,j])
  }
  else{}
  j<-j+1
}

# Definimos la tarea

my_task<-as_task_regr(datos,target = "salida")
```

```
# Preproceso

preproceso_kknn<- po("removeconstants") %>>%
  po("imputelearner",lrn("regr.rpart")) %>>%
  po("imputemode") %>>%
  po("scale")

# Unimos con el learner

 graph_knn_h<-preproceso_kknn %>>% knn_lrn_h
 graph_kknn<-as_learner(graph_knn_h)

      set.seed(100365469)
# Dividimos los datos en train y test

trainvalid<-datos[1:(9*365),]
test<-datos[(9*365+1):(12*365),]

# Validación
desc_outer<- rsmp("custom")
desc_outer$instantiate(my_task,train=list(1:(6*365)),test=(list((6*365+1)
:nrow(trainvalid))))

# Evaluación de los hiper-parámetros

desc_inner <- rsmp("holdoutorder",ratio=6/9)

# Definición del espacio de búsqueda, del parámetro del número de vecinos
knn_space <- ps(
  regr.kknn.k = p_int(lower=1, upper=30)
)

generate_design_grid(knn_space, param_resolutions = c(regr.kknn.k =30))

      # Definimos de k=1 a k=30 vecinos

# Definición la forma de "tunear" los hiperparámetros

terminator <- trm("none")
tuner <- tnr("grid_search", param_resolutions=c(regr.kknn.k=30))

# Ajustamos el nuevo learner

knn_hyper <- AutoTuner$new(
  learner = graph_kknn,
  resampling = desc_inner,
  measure = msr("regr.rae"),
  search_space = knn_space,
```

```
  terminator = terminator,
  tuner = tuner,
  store_tuning_instance = TRUE
)

# Evaluamos el nuevo learner con su ajuste

knn_h_resample <- resample(my_task, knn_hyper, desc_outer,store_models =
TRUE)

      # Calculamos el error

error_knn_h <- knn_h_resample$aggregate(measure)

      ## El error del modelo KNN con ajuste de hiperparámetros es:
0.3610033
```

Errores Modelos KNN

Sin Ajuste Hiperparámetros	Con Ajuste Hiperparámetros
0.3772216	0.3610033

Como vemos en la tabla, el ajuste con hiperparámetros nos da un error menor.

Modelo Rpart Con Ajuste Hiper-Parámetros

Para este modelo ajustamos los parámetros de min_split(número mínimo de observaciones en un nodo para que se realice la separación) y max_depth(número máximo de la profundidad de nodos del árbol final).

En este caso usamos random_search para el método de busca y combinación de hiper-parámetros, que cogerá muestras aleatorias del espacio de búsqueda y realizara distintas combinaciones.

```
      # Leemos los datos
datos<-readRDS("disp_38.rds")

# Definimos el learner
rpart_lrn_h<-lrn("regr.rpart")

# Como Rpart no permite carácteres, los convertimos a factores
# A continuación, convertimos los "characters" a factores

j<-1

for(j in 1:ncol(datos)){
  if(is.character(datos[,j])){
    datos[,j]<-as.factor(datos[,j])
  }
```

```
  else{}
  j<-j+1
}

# Definimos la tarea

my_task<-as_task_regr(datos,target = "salida")

# Preproceso y escalado

preproceso_rpart<-po("imputelearner",lrn("regr.rpart"))%>>%
  po("imputemode") %>>%
  po("scale") %>>%
  po("removeconstants")

# Unimos con el learner

graph_rpart_h<-preproceso_rpart %>>% rpart_lrn_h
graph_r_h<-as_learner(graph_rpart_h)

      # Fijamos la semilla del RNG
set.seed(100365469)

# Dividimos en train y test

trainvalid<-datos[1:(9*365),]
test<-datos[(9*365+1):(12*365),]

# Validación externa

desc_outer <- rsmp("custom")
desc_outer$instantiate(my_task,train=list(1:(6*365)),test=(list((6*365+1)
:nrow(trainvalid))))

# Evaluación de los hiper-parámetros(interna)

desc_inner <- rsmp("holdoutorder",ratio=6/9)

# Definimos el espacio de búsqueda

rpart_space <- ps(
  regr.rpart.minsplit  = p_int(lower = 10, upper = 20),
  regr.rpart.maxdepth = p_int(lower = 2, upper = 20)
)

# Método de búsqueda es "random_search" en este caso con 10 evaluaciones

terminator <- trm("evals", n_evals = 10 )
tuner <- tnr("random_search")
```

```
# Ajustamos el nuevo learner

rpart_hyper <- AutoTuner$new(
  learner = graph_r_h,
  resampling = desc_inner,
  measure = msr("regr.rae"),
  search_space = rpart_space,
  terminator = terminator,
  tuner = tuner
)

# Evaluamos el nuevo learner

rpart_h_resample <- resample(my_task, rpart_hyper,
desc_outer,store_models = TRUE)

      # Calculamos el error
error_rpart_h <- rpart_h_resample$aggregate(measure)

      ## El error del modelo Rpart con ajuste de hiperparámetros es:
0.4274983
```

A continuación, se compara los errores Rpart con y sin ajuste de Hiper parámetros.

Sin Ajuste Hiperparámetros	**Con Ajuste Hiperparámetros**
0.4195004	0.4274983

Como observamos en la tabla, apenas hay diferencia entre ambos, aunque el modelo con ajuste da un error mayor.

Modelo SVM Lineal Con Ajuste Hiper-Parámetros

Para el modelo SVM lineal solo ajustaremos el coste, ya que es uno de los parámetros más importantes del modelo que controla la penalización del modelo cuando falla.

```
datos<-readRDS("disp_38.rds")

# Definimos el learner
svm_l_lrn<-lrn("regr.svm",kernel="linear",type="eps-regression")

 # Como SVM solo trabaja con numéricos y enteros convertimos los datos
```

```r
# Convertimos los "characters" a factores

j<-1

for(j in 1:ncol(datos)){
  if(is.character(datos[,j])){
    datos[,j]<-as.factor(datos[,j])
  }
  else{}
  j<-j+1
}

# Convertimos las variables categóricas ordinales a enteros

k<-1

for(k in 1:ncol(datos)){
  if(is.ordered(datos[,k])){
    datos[,k]<-as.integer(datos[,k])
  }
  else{}
  k<-k+1
}

# Ahora creamos variables dummies para los factores no ordinales.

datos <- createDummyFeatures(datos, target = "salida")

# Definimos la tarea

my_task<-as_task_regr(datos,target="salida")

# Preproceso, imputamos y escalamos

 preproceso_svm_h<-po("imputelearner",lrn("regr.rpart"))%>>%
 po("scale") %>>%
 po("removeconstants")
# Unimos con el learner

 graph_svm_h<-preproceso_svm_h %>>% svm_l_lrn
 graph_h<-as_learner(graph_svm_h)

      # Evaluación del modelo
set.seed(100365469)

trainvalid<-datos[1:(9*365),]
test<-datos[(9*365+1):(12*365),]

desc_outer <- rsmp("custom")
```

```
desc_outer$instantiate(my_task,train=list(1:(6*365)),test=(list((6*365+1)
:nrow(trainvalid))))

# Evaluación de los hiper-parámetros

desc_inner <- rsmp("holdoutorder",ratio=6/9)

# Definimos el espacio de búsqueda
svm_space <- ps(
  regr.svm.cost = p_dbl(-10, 10, trafo=function(x) 2^x)
)

set.seed(100365449)
generate_design_random(svm_space, 100)

      # 10 evaluaciones con random search
terminator <- trm("evals", n_evals = 10)
tuner <- tnr("random_search")

# Nuevo learner que se autoajusta sus hiper-par
svm_hyper <- AutoTuner$new(
  learner = graph_h,
  resampling = desc_inner,
  measure = msr("regr.rae"),
  search_space = svm_space,
  terminator = terminator,
  tuner=tuner,
  store_tuning_instance = TRUE)

# Evaluamos el learner con su autoajuste de hiperparámetros

svm_l_h_resample <- resample(my_task, svm_hyper, desc_outer,store_models
= TRUE)

      # Error del learner con autoajuste

error_svm_l_hyper<-svm_l_h_resample$aggregate(msr("regr.rae"))

      ## El error del modelo SVM Lineal con ajuste de hiperparámetros es:
0.3100432
```

Errores Modelos SVM Lineales

Sin Ajuste Hiperparámetros	**Con Ajuste Hiperparámetros**
0.3103053	0.3100432

En esta tabla observamos que, aunque el modelo sin ajuste da menor error, la diferencia entre los 2 modelos es mínima.

Modelo SVM Radial Con Ajuste Hiper-Parámetros

En el modelo SVM radial ajustamos el parámetro de coste y gamma.

```
datos<-readRDS("disp_38.rds")

# Definimos el learner
svm_r_h<-lrn("regr.svm",kernel="radial",type = "eps-regression")


 # Como SVM solo trabaja con numéricos y enteros convertimos los datos

# Convertimos los "characters" a factores

j<-1

for(j in 1:ncol(datos)){
  if(is.character(datos[,j])){
    datos[,j]<-as.factor(datos[,j])
  }
  else{}
  j<-j+1
}

# Convertimos las variables categóricas ordinales a enteros

k<-1

for(k in 1:ncol(datos)){
  if(is.ordered(datos[,k])){
    datos[,k]<-as.integer(datos[,k])
  }
  else{}
  k<-k+1
}

# Ahora creamos variables dummies para los variables categóricas
nominales.

datos <- createDummyFeatures(datos, target = "salida")

# Convertimos las variables categóricas a dummys

datos<-createDummyFeatures(datos,target="salida")

# Definimos la tarea
```

```
my_task<-as_task_regr(datos,target="salida")

# Preproceso
 preproceso_svm_r<-po("imputemedian")%>>%
 po("scale") %>>%
 po("removeconstants")
# Unimos con el learner

 graph_svm_r<-preproceso_svm_r %>>% svm_r_h
 graph_r<-as_learner(graph_svm_r)

      # Evaluación del modelo
set.seed(100365469)

trainvalid<-datos[1:(9*365),]
test<-datos[(9*365+1):(12*365),]

desc_outer <- rsmp("custom")
desc_outer$instantiate(my_task,train=list(1:(6*365)),test=(list((6*365+1)
:nrow(trainvalid))))

# Evaluación de los hiper-parámetros

desc_inner <- rsmp("holdoutorder",ratio=6/9)

# Definimos el espacio de búsqueda
svm_space_r <- ps(
  regr.svm.gamma = p_dbl(lower=-10, upper=10, trafo=function(x) 2^x),
  regr.svm.cost  = p_dbl(lower=-10, upper=10, trafo=function(x) 2^x)
)

generate_design_random(svm_space_r,100)

      # 10 evaluaciones con random search
terminator <- trm("evals", n_evals = 10)
tuner <- tnr("random_search")

# Nuevo learner que se autoajusta sus hiper-pararámetros
svm_hyper_r <- AutoTuner$new(
  learner = graph_r,
  resampling = desc_inner,
  measure = msr("regr.rae"),
  search_space = svm_space_r,
  terminator = terminator,
  tuner=tuner,
  store_tuning_instance = TRUE)

# Evaluamos el learner con su autoajuste de hiperparámetros
```

```
svm_r_h_resample<- resample(my_task, svm_hyper_r, desc_outer,store_models
= TRUE)

      # Error del learner con autoajuste

error_svm_r_hyper<-svm_r_h_resample$aggregate(measure)

      ## El error del modelo SVM Radial con ajuste de hiperparámetros es:
0.306545
```

Errores Modelos SVM Radiales

Sin Ajuste Hiperparámetros	Con Ajuste Hiperparámetros
0.3075657	0.3065450

Al igual que el modelo svm lineal apenas hay diferencia aunque el modelo con ajuste da mejores resultados.

3.4) Método Ensembles

Modelo Random Forest Sin Ajuste Hiper-Parámetros

Creamos un modelo con random forest con el método ranger.

```
# Primero definimos el learner
ranger_lrn<-lrn("regr.ranger")
ranger_lrn$feature_types

      ## [1] "logical"   "integer"   "numeric"   "character" "factor"
"ordered"

      # Trabaja con lógicos, enteros, numéricos, carácteres, factores y
categóricos ordinales

      datos<-readRDS("disp_38.rds")

# A continuación, convertimos los "characters" a factores

j<-1

for(j in 1:ncol(datos)){
  if(is.character(datos[,j])){
    datos[,j]<-as.factor(datos[,j])
  }
  else{}
  j<-j+1
}
```

```
# Definimos la tarea
 my_task<-as_task_regr(datos,target="salida")

# Preproceso
# Imputamos y escalamos

 preproceso_r<- po("removeconstants") %>>%
 po("imputelearner",lrn("regr.rpart"))%>>%
 po("imputemode") %>>%
 po("scale")

# Unimos con el learner

 graph_r<-preproceso_r %>>% ranger_lrn
 graph_ranger<-as_learner(graph_r)

      # Estrategia de validación
 set.seed(100365469)

 trainvalid<-datos[1:(9*365),]
 test<-datos[(9*365+1):(12*365),]

 res_desc_r<-rsmp("custom")

res_desc_r$instantiate(my_task,train=list(1:(6*365)),test=(list((6*365+1)
:nrow(trainvalid))))

# Entrenamos el modelo y validamos el modelo

 ranger_resample<-resample(task=my_task,learner=graph_ranger,resampling =
res_desc_r,store_models = TRUE)

      # Calculamos el error

 error_ranger<-ranger_resample$aggregate(measure)

      ## El error del modelo ranger es: 0.3074249
```

Modelo Random Forest Con Ajuste Hiper-Parámetros

Ajustamos el "mtry" y el número de árboles.

```
datos<-readRDS("disp_38.rds")

# A continuación, convertimos los "characters" a factores

j<-1
```

```
for(j in 1:ncol(datos)){
  if(is.character(datos[,j])){
    datos[,j]<-as.factor(datos[,j])
  }
  else{}
  j<-j+1
}


# Definimos la tarea
 my_task<-as_task_regr(datos,target="salida")

# A continuación definimos el learner
ranger_lrn_h<-lrn("regr.ranger")

# Preproceso
 preproceso_ranger_h<- po("removeconstants") %>>%
   po("imputelearner",lrn("regr.rpart"))%>>%
   po("imputemode") %>>%
   po("scale")
# Unimos con el learner

 graph_r_h<-preproceso_ranger_h %>>% ranger_lrn_h
 graph_learner_h<-as_learner(graph_r_h)

      # Evaluación del modelo
set.seed(100365469)

trainvalid<-datos[1:(9*365),]
test<-datos[(9*365+1):(12*365),]

desc_outer_r <- rsmp("custom")
desc_outer_r$instantiate(my_task,train=list(1:(6*365)),test=(list((6*365+
1):nrow(trainvalid))))

# Evaluación de los hiper-parámetros

desc_inner_r <- rsmp("holdoutorder",ratio=6/9)

# Definimos el espacio de búsqueda
ranger_space <- ps(
  regr.ranger.num.trees = p_int(lower=1, upper=500),
  regr.ranger.mtry = p_int(lower = 1, upper =50))



      # Definición de terminación con 10 evaluaciones
terminator <- trm("evals", n_evals = 10)
tuner <- tnr("random_search")
```

```
# Nuevo learner que se autoajusta sus hiper-par
ranger_hyper <- AutoTuner$new(
  learner = graph_learner_h,
  resampling = desc_inner_r,
  measure = msr("regr.rae"),
  search_space = ranger_space,
  terminator = terminator,
  tuner=tuner,
  store_tuning_instance = TRUE)

# Evaluamos el learner con su autoajuste de hiperparámetros

ranger_resample <- resample(my_task, ranger_hyper,
desc_outer_r,store_models = TRUE)

      # Error del learner con autoajuste

error_ranger_h<-ranger_resample$aggregate(msr("regr.rae"))

      ## El error del modelo Ranger con ajuste de hiperparámetros es
0.3055202
```

Errores Modelos Ranger

Sin Ajuste Hiperparámetros	Con Ajuste Hiperparámetros
0.3074249	0.3055202

En la tabla se observa que el modelo con el ajuste da ligéramente mejores resultados, aunque apenas hay diferencia. De momento es el modelo que mejores resultados ha dado.

Modelo Gradient Boosting: Método XGBoost Sin Ajuste Hiper-Parámetros

```
      # Primero definimos el learner
xgb_lrn<-lrn("regr.xgboost")

xgb_lrn$feature_types

      ## [1] "logical" "integer" "numeric"

      # Trabaja con lógicos, enteros y numéricos

      datos<-readRDS("disp_38.rds")

 # Como XGBOOST solo trabaja con numéricos y enteros convertimos los
```

```r
datos

# A continuación, convertimos los "characters" a factores

j<-1

for(j in 1:ncol(datos)){
  if(is.character(datos[,j])){
    datos[,j]<-as.factor(datos[,j])
  }
  else{}
  j<-j+1
}

# Convertimos las variables categóricas ordinales a enteros

k<-1

for(k in 1:ncol(datos)){
  if(is.ordered(datos[,k])){
    datos[,k]<-as.integer(datos[,k])
  }
  else{}
  k<-k+1
}

# Ahora creamos variables dummies para los factores nominales.

datos <- createDummyFeatures(datos, target = "salida")

# Convertimos las categóricas en dummys

datos<-createDummyFeatures(datos,target = "salida")

# Definimos la tarea

 my_task<-as_task_regr(datos,target="salida")


# Preproceso

 preproceso_xgb<- po("removeconstants") %>>%
 po("imputemedian") %>>%
 po("scale")

# Unimos con el learner
```

```
graph_xgb<-preproceso_xgb %>>% xgb_lrn
graph_learner_xgb<-as_learner(graph_xgb)

     # Estrategia de validación

set.seed(100365469)

trainvalid<-datos[1:(9*365),]
test<-datos[(9*365+1):(12*365),]

res_desc_x<-rsmp("custom")

res_desc_x$instantiate(my_task,train=list(1:(6*365)),test=(list((6*365+1)
:nrow(trainvalid))))

# Entrenamos el modelo

xgboost_resample<-
resample(my_task,graph_learner_xgb,res_desc_x,store_models = TRUE)

     # Calculamos el error

error_xgb<-xgboost_resample$aggregate(measure)

     ## El error del modelo XGboosting sin ajuste es: 1.678101
```

Como vemos el error que obtenemos es mayor que 1 lo que indica que el modelo ajustado es peor que un modelo trivial/básico.

Modelo Gradient Boosting Con Ajuste Hiper-Parámetros

En este modelo ajustaremos “nround”(indica el número de iteraciones que se realizaran antes de detener el ajuste) y “eta”(tasa aprendizaje del modelo).

```
datos<-readRDS("disp_38.rds")

# Definimos el learner

xgb_lrn_h<-lrn("regr.xgboost")

      # Como XGBOOST solo trabaja con numéricos y enteros convertimos
los datos

# A continuación, convertimos los "characters" a factores

j<-1

for(j in 1:ncol(datos)){
  if(is.character(datos[,j])){
    datos[,j]<-as.factor(datos[,j])
  }
```

```
  else{}
  j<-j+1
}

# Convertimos las variables categóricas ordinales a enteros

k<-1

for(k in 1:ncol(datos)){
  if(is.ordered(datos[,k])){
    datos[,k]<-as.integer(datos[,k])
  }
  else{}
  k<-k+1
}

# Ahora creamos variables dummies para los factores nominales.

datos <- createDummyFeatures(datos, target = "salida")

# Definimos la tarea

 my_task<-as_task_regr(datos,target="salida")

# Preproceso
preproceso_xgb_h<-po("imputemedian")%>>%
  po("scale") %>>%
  po("removeconstants")
# Unimos con el learner

graph_xgb<-preproceso_xgb_h %>>% xgb_lrn_h
graph_xgb_h<-as_learner(graph_xgb)

      # Evaluación del modelo

set.seed(100365469)

trainvalid<-datos[1:(9*365),]
test<-datos[(9*365+1):(12*365),]

desc_outer <- rsmp("custom")
desc_outer$instantiate(my_task,train=list(1:(6*365)),test=(list((6*365+1)
:nrow(trainvalid))))

# Evaluación de los hiper-parámetros

desc_inner <- rsmp("holdoutorder",ratio=6/9)

# Definición del espacio de búsqueda
```

```
xgb_space <- ps(
  regr.xgboost.eta = p_dbl(lower = 0.01, upper = 0.99),
  regr.xgboost.nrounds=p_int(lower = 100, upper = 500)
)

# Definición de terminación: 20 evaluaciones
terminator <- trm("evals", n_evals = 20)
tuner <- tnr("random_search")
measure<-msr("regr.rae")

# Nuevo learner que se autoajusta sus hiper-pararámetros
xgb_h <- AutoTuner$new(
  learner = graph_xgb_h,
  resampling = desc_inner,
  measure = measure,
  search_space = xgb_space,
  terminator = terminator,
  tuner = tuner
)

# Evaluamos el learner con autoajuste
set.seed(100365469)

xgb_h_resample <- resample(my_task, xgb_h, desc_outer,store_models =
TRUE)

      # Calculamos el error
error_xgb_h <- xgb_h_resample$aggregate(measure)

      ## El error del modelo XGBOOST Con Ajuste Hiperparámetros es:
0.3070803
```

Errores Modelos XGB

Sin Ajuste Hiperparámetros	**Con Ajuste Hiperparámetros**
1.6781014	0.3070803

Como se observa en la tabla, el error baja ≈ 5 veces el error del modelo xgboost sin ajuste de hiper-parámetros.

Conclusiones de todos los modelos:

Comparamos todos los modelos y en base a ello escogeremos el modelo que presente los resultados más óptimos.

Modelo Linear	Modelo Cubist
0.3179911	0.3274306

	Sin Ajuste de Hiperparámetros	Con Ajuste de Hiperparámetros
Rpart	0.4195004	0.4274983
KNN	0.3772216	0.3610033
SVM Lineal	0.3103053	0.3100432
SVM Radial	0.3075657	0.3065450
Random Forest	0.3074249	0.3055202
Xgboost	1.6781014	0.3070803

En esta tabla observamos los modelos ordenados en función del rendimiento que nos proporciona el método RAE. Los modelos con un RAE < 0.40 están marcados en verde(de menor a mayor intensidad, en función del error) y los modelos cuyo RAE es > 0.40 están marcados en rojo.

```
      ## El modelo con el menor error es el que corresponde con: Modelo
Random Forest(Ranger) Con Ajuste Hiperparámetros cuyo RAE es: 0.3055202

      ## El modelo con el mayor error es el que corresponde con: Modelo
XGBOOST Sin Ajuste Hiperparámetros cuyo RAE es: 1.678101
```

Observamos que los mejores modelos son los 2 ensembles con ajuste de hiper-parámetros y el svm-radial.

Como era de esperar, ya que en la gráfica inicial vimos que la serie mostraba un patrón no lineal los modelos no lineales han dado mejores resultados. De hecho SVM con el kernel radial es el 2 mejor modelo.

4) Modelo Final

Escogemos el modelo Ranger(Random Forest) ya que es el modelo con el que menor error hemos conseguido para crear el modelo final.

a) Estimación del error del modelo final con los datos de test(los 3 últimos años)

```
datos<-readRDS("disp_38.rds")
```

```
# A continuación, convertimos los "characters" a factores

j<-1

for(j in 1:ncol(datos)){
  if(is.character(datos[,j])){
    datos[,j]<-as.factor(datos[,j])
  }
  else{}
  j<-j+1
}


# Definimos la tarea
 my_task<-as_task_regr(datos,target="salida")

# A continuación definimos el learner
ranger_lrn_f<-lrn("regr.ranger")

# Preproceso
 preproceso_ranger_f<- po("removeconstants") %>>%
   po("imputelearner",lrn("regr.rpart"))%>>%
   po("imputemode") %>>%
   po("scale")
# Unimos con el learner

 graph_r_f<-preproceso_ranger_f %>>% ranger_lrn_f
 graph_learner_f<-as_learner(graph_r_f)

      ## El error estimado para el modelo final es: 0.3176346
```

Por tanto el valor del RAE para el modelo final haciendo regresión con el learner random forest(ranger) es ≈ 0.31. Es bastante parecido al modelo ranger que hicimos con ajuste de hiper-parámetros.

b) Modelo Final

Vamos a construir el modelo final con el método de random forest.

```
# Leemos los datos con los que entrenamos
datos<-readRDS("disp_38.rds")

# Leemos los datos para el test

test<-readRDS("compet_38.rds")

# A continuación, convertimos los "characters" a factores

j<-1
```

```
for(j in 1:ncol(datos)){
  if(is.character(datos[,j])){
    datos[,j]<-as.factor(datos[,j])
  }
  else{}
  j<-j+1
}


k<-1

for(k in 1:ncol(test)){
  if(is.character(test[,k])){
    test[,k]<-as.factor(test[,k])
  }
  else{}
  k<-k+1
}


# Definimos la tarea
final_task<-as_task_regr(datos,target="salida")

# A continuación definimos el learner
final_lrn<-lrn("regr.ranger")

# Preproceso
final_pre<- po("removeconstants") %>>%
   po("imputelearner",lrn("regr.rpart"))%>>%
   po("imputemode") %>>%
   po("scale")

# Unimos con el learner

 graph_final<-final_pre %>>% final_lrn
 graph_lrn_final<-as_learner(graph_final)

      # Fijamos la semilla
set.seed(100365469)

# Evaluación de los hiper-parámetros

desc_inner_f <- rsmp("holdoutorder",ratio=9/12)

# Definimos el espacio de búsqueda
final_ranger_space <- ps(
  regr.ranger.num.trees = p_int(lower=1, upper=500),
  regr.ranger.mtry = p_int(lower = 1, upper =50))
```

```
generate_design_random(final_ranger_space, 100)

      # Definición de terminación
final_terminator <- trm("evals", n_evals = 5)
final_tuner <- tnr("random_search")

# Nuevo learner que se autoajusta sus hiper-pararámetros
ranger_final <- AutoTuner$new(
  learner = graph_lrn_final,
  resampling = desc_inner_f,
  measure = msr("regr.rae"),
  search_space = final_ranger_space,
  terminator=final_terminator,
  tuner=final_tuner,
  store_tuning_instance = TRUE)

# Entrenamos el modelo final

ranger_final$train(final_task)

      # Guardamos el modelo
saveRDS(ranger_final,file="Modelo Final.rds")
```

c) Por último cálculamos las predicciones

```
      # Calculamos las predicciones

ranger_test<-ranger_final$predict_newdata(test)

# Guardamos las predicciones
write.table(ranger_test$response,sep = "\t" ,row.names=TRUE,file =
"Predicciones Modelo Final.txt")
```

5) Ajuste de hiperparámetros con hyperband

Hyperband elimina las configuraciones de rendimiento desde el principio durante su proceso de entrenamiento con el objetivo de aumentar la eficiencia del tuner. Para ello, se construyen varios soportes con un conjunto asociado de configuraciones para cada uno. Esta configuración se inicializa mediante muestreo estocástico, a menudo uniforme. Cada soporte se divide en varias etapas y las configuraciones se evalúan para un presupuesto creciente en cada etapa. Hay que tener en cuenta que actualmente todas las configuraciones se entrenan completamente desde el principio, por lo que no se realizan actualizaciones en línea de los modelos.

Se inicializan diferentes soportes con diferente número de configuraciones y diferentes tamaños. Para identificar el presupuesto para evaluar el hyperband, hay

que especificar explícitamente qué hiperparámetro influye en el presupuesto etiquetando un solo hiperparámetro en el conjunto de parámetros.

La ventaja de hyper-band como método para ajustar hiperparámetros es que, a diferencia de “grid-search” y “random-search” no busca en un espacio aleatorio/discretizado los valores de los hiper-parámetros más óptimos y “a ciegas”. Una de las formas es aplicando el “budget” para asignar un presupuesto a la búsqueda del hiper-parámetro para así optimizar el tiempo de búsqueda, eliminando las combinaciones de hiper-parámetros que tengan un rendimiento más bajo.

En cada paso, el presupuesto/“budget” aumenta en una cantidad “eta” y solo los mejores 1/“eta” puntos se usan en el siguiente paso.

En este caso, asignaremos el “budget” al número de árboles del modelo.

```
datos<-readRDS("disp_38.rds")

# A continuación, convertimos los "characters" a factores

j<-1

for(j in 1:ncol(datos)){
  if(is.character(datos[,j])){
    datos[,j]<-as.factor(datos[,j])
  }
  else{}
  j<-j+1
}

# Definimos la tarea
 my_task<-as_task_regr(datos,target="salida")

# A continuación definimos el learner
ranger_lrn_hb<-lrn("regr.ranger")

# Preproceso
 preproceso_ranger_hb<- po("removeconstants") %>>%
   po("imputelearner",lrn("regr.rpart"))%>>%
   po("imputemode") %>>%
   po("scale")
# Unimos con el learner

 graph_r_hb<-preproceso_ranger_hb %>>% ranger_lrn_hb
 graph_learner_hb<-as_learner(graph_r_hb)

      # Evaluación del modelo
set.seed(100365469)

trainvalid<-datos[1:(9*365),]
test<-datos[(9*365+1):(12*365),]
```

```
desc_outer_r <- rsmp("custom")
desc_outer_r$instantiate(my_task,train=list(1:(6*365)),test=(list((6*365+
1):nrow(trainvalid))))

# Evaluación de los hiper-parámetros

desc_inner_r <- rsmp("holdoutorder",ratio=6/9)

# Definimos el espacio de búsqueda
ranger_hb_space <- ps(
  regr.ranger.num.trees = p_int(lower=5, upper=500,tags = "budget"),
  regr.ranger.mtry = p_int(lower = 1, upper =50))

generate_design_random(ranger_hb_space, 100)

      # Definición de terminación en 5 evaluaciones
terminator <- trm("evals", n_evals = 5)
tuner <- tnr("hyperband")

# Nuevo learner que se autoajusta sus hiper-pararámetros
ranger_hyperband <- AutoTuner$new(
  learner = graph_learner_hb,
  resampling = desc_inner_r,
  measure = msr("regr.rae"),
  search_space = ranger_hb_space,
  terminator = terminator,
  tuner=tuner,
  store_tuning_instance = TRUE)

# Evaluamos el learner con su autoajuste de hiperparámetros

ranger_hb <- resample(my_task, ranger_hyperband, desc_outer_r)

      # Error del learner con autoajuste

error_ranger_hb<-ranger_hb$aggregate(msr("regr.rae"))

      ## El error del modelo Ranger con ajuste de hiper-parámetros hyper-
band 0.3261237
```

El error estimado con el método de hyper-band es ≈ 0.32. Es un poco peor que los modelos anteriores pero en términos de error no hay mucha diferencia.

Errores Modelos Ranger

Sin Ajuste de Hiperparámetros	**Con Ajuste Hiperparámetros**	**Con Ajuste Hyperband**
0.3074249	0.3055202	0.3261237