

Grado Estadística y Empresa
2021/22

Distancias Estadísticas: Teoría y Aplicaciones

Fabio Scielzo Ortiz

ÍNDICE GENERAL

1. DISTANCIAS ESTADÍSTICAS:	1
1.1. Definición de distancia:	1
1.2. Matriz de distancias:	2
2. DISTANCIAS CON VARIABLES CUANTITATIVAS:	3
2.1. Distancia Euclídea:	3
2.1.1. Inconvenientes:	3
2.1.2. Aplicación en R: Data-set	4
2.1.3. Aplicación en R: Distancia euclídea	5
2.2. Distancia Minkowski:	7
2.2.1. Inconvenientes:	7
2.2.2. Casos particulares de la distancia de Minkowski:	7
2.3. Aplicación en R: Distancia de Minkowski:	9
2.3.1. Aplicación en R: Distancia Dominante.	12
2.4. Distancia de Canberra:	14
2.4.1. Inconvenientes:	14
2.4.2. Aplicación en R: Distancia Canberra.	15
2.5. Distancia de Karl Pearson:	17
2.5.1. Inconvenientes	17
2.5.2. Aplicación en R: Distancia de Pearson.	18
2.6. Distancia de Mahalanobis:	20
2.6.1. Ventajas:	20
2.6.2. Aplicación en R: Distancia de Mahalanobis	21
3. DISTANCIAS CON VARIABLES CATEGÓRICAS:	23
3.1. Similaridad:	23
3.2. Matriz de Similaridades:	23
3.3. Pasar de una similaridad a una distancia:	24
3.4. Similaridades con variables categóricas binarias:	24
3.4.1. Matrices con los parámetros a, b, c y d:	24

3.4.2. Aplicación en R:	26
3.4.3. Coeficiente de Sokal: (Simple matching coefficient)	27
3.4.4. Coeficiente de Jaccard:	32
3.4.5. Aplicación en R: Coeficiente de Similaridad de Jaccard:.	33
3.4.6. Más coeficientes de similaridad:	37
3.5. Similaridades con variables categoricas múltiples	38
3.5.1. Coeficiente de Coincidencias:.	38
3.5.2. Aplicación en R:	39
3.5.3. Coeficiente de similaridad de Coincidencias:	40
3.5.4. Mas coeficientes de similaridad:.	43
4. DISTANCIAS CON VARIABLES DE TIPO MIXTO:	44
4.1. Coeficiente de similaridad de Gower:	44
4.1.1. Distancia de Gower:	45
4.1.2. Propiedades:	46
4.1.3. Aplicación en R: Coeficiente de Gower	47
4.2. Coeficiente de similaridad de Gower-Mahalanobis:.	51
4.2.1. Distancia de Gower-Mahalanobis:	51
4.2.2. Aplicación en R: Coeficiente de similaridad de Gower-Mahalanobis	52

1. DISTANCIAS ESTADÍSTICAS:

El concepto de distancia entre elementos de un conjunto ε permite interpretar geométricamente muchas técnicas clásicas del análisis multivariante .

Esta interpretación es posible tanto con variables cuantitativas como categoricas, o incluso cuando no se dispone de variables, siempre que tenga sentido obtener una medida de proximidad entre los elementos de ε

1.1. Definición de distancia:

Dado un conjunto de elementos ε

Casi-Métrica:

Se denomina **casi-métrica** o disimilaridad a toda aplicación $\delta : \varepsilon \times \varepsilon \rightarrow \mathbb{R}$ que cumpla las siguientes propiedades:

- 1) $\delta(i, j) \geq 0, \forall i, j$
- 2) $\delta(i, i) = 0, \forall i$
- 3) $\delta(i, j) = \delta(j, i), \forall i, j$

Semi-Métrica:

Se denomina **semi-métrica** a toda disimilaridad que cumpla la desigualdad triangular:

- 4) $\delta(i, j) \leq \delta(i, k) + \delta(k, i), \forall i, j, k$

Métrica:

Se denomina **métrica** a toda semi-métrica que cumple:

- 5) $\delta(i, j) = 0 \Leftrightarrow i = j$

Distancia:

Una **distancia** es una **métrica** o una **semi-métrica**

1.2. Matriz de distancias:

Cuando ε sea un conjunto finito , tendremos una matriz de distancias:

Matriz de distancias:

$$D = \begin{pmatrix} 0 & \delta_{12} & \dots & \delta_{1n} \\ \delta_{21} & 0 & \dots & \delta_{2n} \\ \dots & \dots & \dots & \dots \\ \delta_{n1} & \delta_{n2} & \dots & 0 \end{pmatrix}$$

con $\delta_{ij} = \delta_{ji}$

También usaremos la matriz de cuadrados de distancias:

Matriz de distancias al cuadrado:

$$D^{(2)} = \begin{pmatrix} 0 & \delta_{12}^2 & \dots & \delta_{1n}^2 \\ \delta_{21}^2 & 0 & \dots & \delta_{2n}^2 \\ \dots & \dots & \dots & \dots \\ \delta_{n1}^2 & \delta_{n2}^2 & \dots & 0 \end{pmatrix}$$

No debe confundirse con $D^2 = D \cdot D$

2. DISTANCIAS CON VARIABLES CUANTITATIVAS:

Sean X_1, \dots, X_p variables cuantitativas,

Sean $x_i = (x_{i1}, \dots, x_{ip})^t$ y $x_j = (x_{j1}, \dots, x_{jp})^t$ los valores (observaciones) de las variables X_1, \dots, X_p para los elementos o individuos i y j de la muestra.

2.1. Distancia Euclidea:

Distancia Euclidea:

La distancia euclidea entre los elementos / individuos i y j respecto de las variables cuantitativas X_1, \dots, X_p se define como:

$$\delta^2(i, j)_{Euclidea} = \sum_{k=1}^p (x_{ik} - x_{jk})^2 = (x_i - x_j)^t \cdot (x_i - x_j)$$

$$\delta(i, j)_{Euclidea} = \sqrt{\sum_{k=1}^p (x_{ik} - x_{jk})^2} = \sqrt{(x_i - x_j)^t \cdot (x_i - x_j)}$$

2.1.1. Inconvenientes:

Pese a que es una de las distancias mas conocidas no es adecuada en muchos casos por las siguientes razones:

- 1) **Presupone** que las **variables** son **incorreladas** y con **varianza unidad**.
- 2) **No es invariante frente a cambios de escala** (cambios de unidades de medida) de las variables.

Veamos que significa esto ultimo con mas detalle:

Si se aplica un cambio de escala a las variables $a \cdot X_j + b$, con $a \neq 1$ y $b \neq 0$

Ahora las observaciones para los elementos i y j son $a \cdot x_i + b$ y $a \cdot x_j + b$

Entonces la distancia euclidea entre los elementos i y j respecto de las variables escaladas $a \cdot X_j + b$ es:

$$\delta^2(i, j)_{Euclidea} = a^2 \cdot (x_i - x_j)^t \cdot (x_i - x_j)$$

2.1.2. Aplicación en R: Data-set

Data-set de trabajo, tendra 4 variables cuantitativas, 3 binarias y 3 categoricas multiples:

```
1  #Cuantitativas
2  X1 <- rnorm(50, mean=10 , sd=15)
3  X2 <- rnorm(50, mean=10 , sd=15)
4  X3 <- rnorm(50, mean=10 , sd=15)
5  X4 <- rnorm(50, mean=10 , sd=15)
6
7  #Binarias
8  X5<- round(runif(50))
9  X6<- round(runif(50))
10 X7<- round(runif(50))
11
12 #Categoricas multiples
13 X8<-round(runif(50, min=0, max=4)) #categorias: 0,1,2,3,4
14 X9<-round(runif(50, min=0, max=3)) #categorias: 0,1,2,3
15 X10<-round(runif(50, min=0, max=5)) #categorias: 0,1,2,3,4,5

1  library(tidyverse)
2
3  Datos_Mixtos<-tibble(X1,X2,X3,X4,X5,X6,X7,X8,X9,X10)
```

Observación: al no haber fijado semilla aleatoria, los resultados numericos que en este trabajo se obtengan no se obtendran si se reproduce el codigo, debido a la aleatoriedad del data-set.

```
1 Datos_Cuantitativos <- Datos_Mixtos%>%select(1:4)
```

X1 <dbl>	X2 <dbl>	X3 <dbl>	X4 <dbl>
-8.1332426	4.8784024	-17.0687714	-4.4326816
-14.2068498	13.0333758	-21.8233349	-0.6493458
12.2132856	-8.7883466	36.6426908	-5.5453174
22.7573377	10.3320840	2.9471420	-14.3266445
6.3147590	25.0873836	0.3277923	18.2358284
-14.8599494	24.0703325	1.0882005	10.4715531
9.3842225	-14.5996736	1.7041652	35.7188878
33.6985681	5.4460857	22.9162756	21.0916602
-0.7572772	15.4888918	13.2406387	-0.5323519
0.9396013	19.2296040	0.7513538	1.7749528
26.5205561	14.3328379	19.7931778	10.5736266
9.9669342	0.3729050	17.9946197	-8.0098499
1.4609010	-4.6219132	9.1251820	-6.1557409
-3.4954412	7.7376606	31.2834967	12.5695518
-5.4234701	10.1284803	37.3394583	18.8686520

1-15 of 50 rows Previous 2 3 4 Next

2.1.3. Aplicación en R: Distancia euclídea

Programamos la distancia Euclídea:

```
1 Dist_Euclídea <- function(i,j, Matriz_Datos_Cuantitativos){
2
3   Matriz_Datos_Cuantitativos=as.matrix(Matriz_Datos_
4     Cuantitativos)
5   Dist_Euclídea = (Matriz_Datos_Cuantitativos[i,] - Matriz_Datos_
6     _Cuantitativos[j,])%*%(Matriz_Datos_Cuantitativos[i,] -
7     Matriz_Datos_Cuantitativos[j,])
8
9   Dist_Euclídea<-sqrt(Dist_Euclídea)
10  return(Dist_Euclídea)
11 }
```

```
1 Dist_Euclídea(1,2, Datos_Cuantitativos)
```

```
[,1]
[1,] 11.84533
```

Programamos la matriz de distancias Euclideas:

```

1  Matriz_Dist_Euclideas <- function( Matriz_Datos_Cuantitativos
    ){
2
3    Matriz_Datos_Cuantitativos=as.matrix(Matriz_Datos_
        Cuantitativos)
4
5    M<-matrix(NA, ncol =dim(Matriz_Datos_Cuantitativos)[1] ,
        nrow=dim(Matriz_Datos_Cuantitativos)[1] )
6
7    for(i in 1:dim(Matriz_Datos_Cuantitativos)[1] ){
8        for(j in 1:dim(Matriz_Datos_Cuantitativos)[1]){
9
10       M[i,j]=Dist_Euclidea(i,j, Matriz_Datos_Cuantitativos)
11
12       }
13     }
14     return(M)
15 }

```

```

1  Matriz_Dist_Euclideas(Datos_Cuantitativos)

```

Las primeras 20 filas y 11 columnas de la matriz de distancias obtenida son:

	[,1]	[,2]	[,3]	[,4]	[,5]	[,6]	[,7]	[,8]	[,9]	[,10]	[,11]
[1,]	0.00000	11.84533	59.05015	38.50322	37.86356	31.07074	51.48620	63.24965	33.17921	25.38435	53.612169
[2,]	11.84533	0.00000	67.94452	46.62932	37.59997	27.76425	56.53597	69.47518	37.63531	27.98753	59.315255
[3,]	59.05015	67.94452	0.00000	41.10073	55.37754	57.73487	54.45374	39.52442	36.47473	47.47500	35.819179
[4,]	38.50322	46.62932	41.10073	0.00000	39.43669	47.14028	57.50246	42.38875	29.59338	28.62276	30.561091
[5,]	37.86356	37.59997	55.37754	39.43669	0.00000	22.58904	43.49754	40.67000	25.71247	18.28512	31.008790
[6,]	31.07074	27.76425	57.73487	47.14028	22.58904	0.00000	52.16279	57.39376	23.26573	18.67626	46.444070
[7,]	51.48620	56.53597	54.45374	57.50246	43.49754	52.16279	0.00000	40.70540	49.55214	48.67063	45.719150
[8,]	63.24965	69.47518	39.52442	42.38875	40.67000	57.39376	40.70540	0.00000	43.00324	46.12542	15.839223
[9,]	33.17921	37.63531	36.47473	29.59338	25.71247	23.26573	49.55214	43.00324	0.00000	13.34834	30.194290
[10,]	25.38435	27.98753	47.47500	28.62276	18.28512	18.67626	48.67063	46.12542	13.34834	0.00000	33.442059
[11,]	53.61217	59.31525	35.81918	30.56109	31.00879	46.44407	45.71915	15.83922	30.19429	33.44206	0.000000
[12,]	39.87673	48.82935	21.04279	23.00235	40.31248	42.48919	49.01121	38.21058	20.54301	28.81216	28.591651
[13,]	29.51941	39.31054	29.84223	27.96591	39.73091	37.82427	44.39472	45.53292	21.39917	26.49875	37.161092
[14,]	51.54321	56.01655	29.60984	47.14121	37.25071	36.22245	45.55953	39.13160	23.76518	34.64779	32.870467
[15,]	59.48205	62.98233	35.57287	55.48836	41.61513	40.84223	48.83189	42.01700	31.74365	41.88321	37.613519
[16,]	59.65716	64.93189	61.34823	41.01327	42.51726	62.89295	46.68495	30.71192	53.67968	48.99879	32.790144
[17,]	62.98522	68.20483	59.86417	39.11678	67.34998	66.98204	94.06408	73.84047	51.13414	53.65182	59.855308
[18,]	52.38393	56.01120	44.85783	34.19970	23.09088	41.23240	46.88377	22.27365	29.90698	30.17712	11.007831
[19,]	46.10638	51.28469	37.46877	20.67733	30.74481	39.81449	57.30302	34.90198	21.05604	24.59085	19.257623
[20,]	62.44051	72.63348	26.63085	41.17312	59.41630	68.61267	46.79356	32.63146	49.28544	54.98109	36.457404

2.2. Distancia Minkowski:

Distancia Minkowski:

La distancia de Minkowski con parametro $q = 1, 2, \dots$ entre los individuos i y j respecto de las variables cuantitativas X_1, \dots, X_k es:

$$\delta_q(i, j)_{Minkowski} = \left(\sum_{k=1}^p |x_{ik} - x_{jk}|^q \right)^{(1/q)}$$

2.2.1. Inconvenientes:

- 1) **Presupone** que las **variables** son **incorreladas** y con **varianza unidad**.
- 2) **No es invariante frente a cambios de escala** (cambios de unidades de medida) de las variables.
- 3) Es difícilmente euclidianizable (veremos mas adelante que significa esto).

2.2.2. Casos particulares de la distancia de Minkowski:

Distancia Euclidea:

$$\delta_2(i, j)_{Minkowski} = \delta(i, j)_{Euclidea} \quad (q = 2)$$

Distancia Manhattan:

Distancia Manhattan:

$$\delta_1(i, j)_{Minkowski} = \sum_{k=1}^p |x_{ik} - x_{jk}| \quad (q = 1)$$

Distancia Dominante:

Distancia Dominante:

$$\delta_{\infty}(i, j)_{Minkowski} = \max\{ |x_{i1} - x_{j1}|, \dots, |x_{ip} - x_{jp}| \} \quad (q \rightarrow \infty)$$

2.3. Aplicación en R: Distancia de Minkowski:

Programamos la distancia de Minkowski:

```
1 Dist_Minkowski <- function(i,j, q , Matriz_Datos_Cuantitativos
  ){
2
3 Matriz_Datos_Cuantitativos=as.matrix(Matriz_Datos_
  Cuantitativos)
4
5 Dist_Minkowski = ( sum( ( abs(Matriz_Datos_Cuantitativos[i,] -
  Matriz_Datos_Cuantitativos[j,]) )^q ) )^(1/q)
6
7 return(Dist_Minkowski)
8 }
```

Programamos la matriz de distancias de Minkowski:

```
1 Matriz_Dist_Minkowski <- function(q , Matriz_Datos_
  Cuantitativos ){
2
3 Matriz_Datos_Cuantitativos=as.matrix(Matriz_Datos_
  Cuantitativos)
4
5 M<-matrix(NA, ncol =dim(Matriz_Datos_Cuantitativos)[1] ,
  nrow=dim(Matriz_Datos_Cuantitativos)[1] )
6
7 for(i in 1:dim(Matriz_Datos_Cuantitativos)[1] ){
8   for(j in 1:dim(Matriz_Datos_Cuantitativos)[1]){
9
10    M[i,j]=Dist_Minkowski(i,j, q , Matriz_Datos_Cuantitativos)
11
12   }
13 }
14 return(M)
15 }
```

Distancia euclidea: (q=2)

```
1 Datos_Cuantitativos<- as.matrix(Datos_Cuantitativos)
2
3 Dist_Minkowski(1,2, q=2, Datos_Cuantitativos)
```

```
[1] 11.84533
```

```
1 Matriz_Dist_Minkowski(q=2 , Datos_Cuantitativos)
```

	[,1]	[,2]	[,3]	[,4]	[,5]	[,6]	[,7]	[,8]	[,9]	[,10]	[,11]
[1,]	0.00000	11.84533	59.05015	38.50322	37.86356	31.07074	51.48620	63.24965	33.17921	25.38435	53.612169
[2,]	11.84533	0.00000	67.94452	46.62932	37.59997	27.76425	56.53597	69.47518	37.63531	27.98753	59.315255
[3,]	59.05015	67.94452	0.00000	41.10073	55.37754	57.73487	54.45374	39.52442	36.47473	47.47500	35.819179
[4,]	38.50322	46.62932	41.10073	0.00000	39.43669	47.14028	57.50246	42.38875	29.59338	28.62276	30.561091
[5,]	37.86356	37.59997	55.37754	39.43669	0.00000	22.58904	43.49754	40.67000	25.71247	18.28512	31.008790
[6,]	31.07074	27.76425	57.73487	47.14028	22.58904	0.00000	52.16279	57.39376	23.26573	18.67626	46.444070
[7,]	51.48620	56.53597	54.45374	57.50246	43.49754	52.16279	0.00000	40.70540	49.55214	48.67063	45.719150
[8,]	63.24965	69.47518	39.52442	42.38875	40.67000	57.39376	40.70540	0.00000	43.00324	46.12542	15.839223
[9,]	33.17921	37.63531	36.47473	29.59338	25.71247	23.26573	49.55214	43.00324	0.00000	13.34834	30.194290
[10,]	25.38435	27.98753	47.47500	28.62276	18.28512	18.67626	48.67063	46.12542	13.34834	0.00000	33.442059
[11,]	53.61217	59.31525	35.81918	30.56109	31.00879	46.44407	45.71915	15.83922	30.19429	33.44206	0.000000
[12,]	39.87673	48.82935	21.04279	23.00235	40.31248	42.48919	49.01121	38.21058	20.54301	28.81216	28.591651
[13,]	29.51941	39.31054	29.84223	27.96591	39.73091	37.82427	44.39472	45.53292	21.39917	26.49875	37.161092
[14,]	51.54321	56.01655	29.60984	47.14121	37.25071	36.22245	45.55953	39.13160	23.76518	34.64779	32.870467
[15,]	59.48205	62.98233	35.57287	55.48836	41.61513	40.84223	48.83189	42.01700	31.74365	41.88321	37.613519
[16,]	59.65716	64.93189	61.34823	41.01327	42.51726	62.89295	46.68495	30.71192	53.67968	48.99879	32.790144
[17,]	62.98522	68.20483	59.86417	39.11678	67.34998	66.98204	94.06408	73.84047	51.13414	53.65182	59.855308
[18,]	52.38393	56.01120	44.85783	34.19970	23.09088	41.23240	46.88377	22.27365	29.90698	30.17712	11.007831
[19,]	46.10638	51.28469	37.46877	20.67733	30.74481	39.81449	57.30302	34.90198	21.05604	24.59085	19.257623
[20,]	62.44051	72.63348	26.63085	41.17312	59.41630	68.61267	46.79356	32.63146	49.28544	54.98109	36.457404

Distancia Manhattan: (q=1)

```
1 Dist_Minkowski(1,2, q=1, Datos_Cuantitativos)
```

```
[1] 22.76648
```

```
1 Matriz_Dist_Minkowski(q=1 , Datos_Cuantitativos)
```

	[,1]	[,2]	[,3]	[,4]	[,5]	[,6]	[,7]	[,8]	[,9]	[,10]	[,11]
[1,]	0.00000	22.76648	88.83738	66.25414	74.72206	58.97984	95.92005	107.90888	52.19619	47.45181	95.97649
[2,]	22.76648	0.00000	111.60386	78.11326	73.61192	45.72249	111.11986	121.97332	51.08606	46.34167	94.86635
[3,]	88.83738	111.60386	0.00000	72.14136	99.87030	111.50327	84.84312	76.08311	65.66282	82.50324	70.39691
[4,]	66.25414	78.11326	72.14136	0.00000	66.37970	78.01267	89.59338	71.21467	52.75921	49.01264	49.51028
[5,]	74.72206	73.61192	99.87030	66.37970	0.00000	30.71644	61.61595	72.46942	48.35155	28.11737	58.08793
[6,]	58.97984	45.72249	111.50327	78.01267	30.71644	0.00000	88.77748	99.63095	45.84046	29.67373	69.92505
[7,]	95.92005	111.11986	84.84312	89.59338	61.61595	88.77748	0.00000	80.19944	88.01778	77.17065	89.30312
[8,]	107.90888	121.97332	76.08311	71.21467	72.46942	99.63095	80.19944	0.00000	75.79830	88.02411	29.70590
[9,]	52.19619	51.08606	65.66282	52.75921	48.35155	45.84046	88.01778	75.79830	0.00000	20.23418	46.09240
[10,]	47.45181	46.34167	82.50324	49.01264	28.11737	29.67373	77.17065	88.02411	20.23418	0.00000	58.31822
[11,]	95.97649	94.86635	70.39691	49.51028	58.08793	69.92505	89.30312	29.70590	46.09240	58.31822	0.00000
[12,]	61.24623	84.01271	32.52021	44.11385	72.27916	83.91213	75.57448	62.82798	38.07168	54.91210	50.89559
[13,]	47.01147	69.77795	43.04675	50.59938	67.75211	69.67737	67.19673	83.34416	32.06783	40.67734	71.41177
[14,]	72.85156	82.33285	55.70880	84.07975	63.78190	59.99048	87.94567	56.37491	41.63416	57.25373	50.09742
[15,]	85.66941	90.36907	61.66432	95.97202	64.34162	68.02669	92.02138	60.45062	53.52643	69.14600	61.98969
[16,]	92.83920	99.67147	117.25872	65.21984	61.23589	89.91824	83.27879	45.50357	90.39047	77.63771	57.40314
[17,]	122.53213	128.98867	105.42092	67.32743	93.14710	106.81417	145.87138	115.54366	78.13660	87.49560	85.83776
[18,]	101.31849	100.20835	85.08087	54.85228	37.57468	58.51911	85.53781	41.11184	49.12229	53.86668	20.51325
[19,]	77.65102	84.10755	58.22622	38.95832	54.28464	65.91762	100.99026	64.19583	33.25548	42.61448	34.48993
[20,]	111.30490	126.50471	50.30227	75.74606	110.90497	122.53794	84.25513	48.92239	80.32969	93.53791	52.81704

2.3.1. Aplicación en R: Distancia Dominante

Programamos la distancia Dominante:

```
1 Dist_Dominante <- function(i,j,  Matriz_Datos_Cuantitativos){
2
3   Matriz_Datos_Cuantitativos=as.matrix(Matriz_Datos_
4     Cuantitativos)
5   Dist_Dominante = max( abs(Matriz_Datos_Cuantitativos[i,] -
6     Matriz_Datos_Cuantitativos[j,]) )
7
8   return(Dist_Dominante)
9 }
```

```
1 Dist_Dominante(1,2, Datos_Cuantitativos)
```

```
[1] 8.154973
```

Programamos la matriz de distancias dominantes:

```
1 Matriz_Dist_Dominante <- function( Matriz_Datos_Cuantitativos
2   ){
3
4   Matriz_Datos_Cuantitativos=as.matrix(Matriz_Datos_
5     Cuantitativos)
6
7   M<-matrix(NA, ncol =dim(Matriz_Datos_Cuantitativos)[1] ,
8     nrow=dim(Matriz_Datos_Cuantitativos)[1] )
9
10  for(i in 1:dim(Matriz_Datos_Cuantitativos)[1] ){
11    for(j in 1:dim(Matriz_Datos_Cuantitativos)[1]){
12
13      M[i,j]=Dist_Dominante(i,j,  Matriz_Datos_Cuantitativos)
14
15    }
16  }
17  return(M)
18 }
```

1 Matriz_Dist_Dominante(Datos_Cuantitativos)

	[,1]	[,2]	[,3]	[,4]	[,5]	[,6]	[,7]	[,8]	[,9]	[,10]	[,11]
[1,]	0.000000	8.154973	53.71146	30.89058	22.668510	19.19193	40.15157	41.83181	30.30941	17.820125	36.861949
[2,]	8.154973	0.000000	58.46603	36.96419	22.151127	22.91154	36.36823	47.90542	35.06397	22.574689	41.616513
[3,]	53.711462	58.466026	0.00000	33.69555	36.314898	35.55449	41.26421	26.63698	24.27724	35.891337	23.121184
[4,]	30.890580	36.964187	33.69555	0.00000	32.562473	37.61729	50.04553	35.41830	23.51461	21.817736	24.900271
[5,]	22.668510	22.151127	36.31490	32.56247	0.000000	21.17471	39.68706	27.38381	18.76818	16.460876	20.205797
[6,]	19.191930	22.911535	35.55449	37.61729	21.174708	0.00000	38.67001	48.55852	14.10267	15.799551	41.380505
[7,]	40.151569	36.368234	41.26421	50.04553	39.687057	38.67001	0.00000	24.31435	36.25124	33.943935	28.932511
[8,]	41.831811	47.905418	26.63698	35.41830	27.383809	48.55852	24.31435	0.00000	34.45585	32.758967	10.518034
[9,]	30.309410	35.063974	24.27724	23.51461	18.768180	14.10267	36.25124	34.45585	0.00000	12.489285	27.277833
[10,]	17.820125	22.574689	35.89134	21.81774	16.460876	15.79955	33.94393	32.75897	12.48928	0.000000	25.580955
[11,]	36.861949	41.616513	23.12118	24.90027	20.205797	41.38051	28.93251	10.51803	27.27783	25.580955	0.000000
[12,]	35.063391	39.817955	18.64807	15.04748	26.245678	24.82688	43.72874	29.10151	15.11599	18.856699	18.583476
[13,]	26.193953	30.948517	27.51751	21.29644	29.709297	28.69225	41.87463	32.23767	20.11081	23.851517	25.059655
[14,]	48.352268	53.106832	18.11487	28.33635	30.955704	30.19530	29.57933	37.19401	18.04286	30.532143	30.015997
[15,]	54.408230	59.162793	24.41397	34.39232	37.011666	36.25126	35.63529	39.12204	24.09882	36.588105	31.944026
[16,]	53.432666	59.506273	41.84906	33.25433	38.984664	60.15937	35.91520	28.12265	46.05670	44.359822	24.999550
[17,]	42.192297	45.975633	41.07966	32.29833	64.860807	57.09653	82.34387	67.71664	46.09263	48.399932	57.198605
[18,]	32.190968	37.812760	31.49515	29.45393	17.291152	38.46586	37.30648	17.26072	24.36319	22.666309	8.373969
[19,]	33.447547	38.202111	30.86640	13.43163	23.005524	33.39351	40.48858	25.86136	19.29084	17.593964	15.343322
[20,]	40.906728	45.661292	19.09769	30.69121	45.446507	46.17093	34.43514	25.80521	35.84801	39.588727	34.691961

2.4. Distancia de Canberra:

Distancia Canberra:

La distancia de Canberra entre los elementos i y j respecto de las variables cuantitativas X_1, \dots, X_p es:

$$\delta(i, j)_{Canberra} = \sum_{k=1}^p \frac{|x_{ik} - x_{jk}|}{|x_{ik}| + |x_{jk}|}$$

2.4.1. Inconvenientes:

- 1) **Presupone** que las **variables** son **incorreladas** y con **varianza unidad**.

Aunque **si** es **invariante frente a cambios de escala** (cambios de unidades de medida) de las variables.

2.4.2. Aplicación en R: Distancia Canberra

Programamos la distancia de Canberra:

```
1 Dist_Canberra <- function(i,j,  Matriz_Datos_Cuantitativos){
2
3   Matriz_Datos_Cuantitativos=as.matrix(Matriz_Datos_
4     Cuantitativos)
5   Dist_Canberra = sum( abs(Matriz_Datos_Cuantitativos[i,] -
6     Matriz_Datos_Cuantitativos[j,])/(abs(Matriz_Datos_
7     Cuantitativos[i,])+ abs(Matriz_Datos_Cuantitativos[j,])) )
8
9   return(Dist_Canberra)
10 }
```

```
1 Dist_Canberra(1,2, Datos_Cuantitativos)
```

```
[1] 1.59386
```

Programamos la matriz de distancias de Canberra:

```
1 Matriz_Dist_Canberra <- function( Matriz_Datos_Cuantitativos )
2   {
3     Matriz_Datos_Cuantitativos=as.matrix(Matriz_Datos_
4       Cuantitativos)
5     M<-matrix(NA, ncol =dim(Matriz_Datos_Cuantitativos)[1] ,
6       nrow=dim(Matriz_Datos_Cuantitativos)[1] )
7     for(i in 1:dim(Matriz_Datos_Cuantitativos)[1] ){
8       for(j in 1:dim(Matriz_Datos_Cuantitativos)[1]){
9
10        M[i,j]=Dist_Canberra(i,j,  Matriz_Datos_Cuantitativos)
11
12      }
13    }
14    return(M)
15  }
```

1 Matriz_Dist_Canberra(Datos_Cuantitativos)

	[,1]	[,2]	[,3]	[,4]	[,5]	[,6]	[,7]	[,8]	[,9]	[,10]	[,11]
[1,]	0.000000	1.593860	3.1115089	2.885963	3.674402	2.955515	4.000000	3.0549842	3.136161	3.595288	3.4921304
[2,]	1.593860	0.000000	3.7903532	3.028892	3.316206	2.319931	4.000000	3.4105796	2.083884	3.192054	3.0474842
[3,]	3.111509	3.790353	0.0000000	2.594523	3.300624	3.942318	2.290583	2.6984357	3.293953	3.816940	2.6679343
[4,]	2.885963	3.028892	2.5945232	0.000000	2.781984	2.860005	2.683301	2.2755692	2.763941	2.815378	1.9793718
[5,]	3.674402	3.316206	3.3006240	2.781984	0.000000	1.828166	2.196915	2.3720506	3.188237	2.088232	2.1215650
[6,]	2.955515	2.319931	3.9423178	2.860005	1.828166	0.000000	2.767181	2.8767838	2.968057	2.005038	2.1541830
[7,]	4.000000	4.000000	2.2905832	2.683301	2.196915	2.767181	0.000000	2.6834021	3.771939	3.111323	2.8619071
[8,]	3.054984	3.410580	2.6984357	2.275569	2.372051	2.876784	2.683402	0.0000000	2.747315	3.285598	0.9737895
[9,]	3.136161	2.083884	3.2939528	2.763941	3.188237	2.968057	3.771939	2.7473155	0.000000	3.000346	2.2371240
[10,]	3.595288	3.192054	3.8169405	2.815378	2.088232	2.005038	3.111323	3.2855984	3.000346	0.000000	2.7168476
[11,]	3.492130	3.047484	2.6679343	1.979372	2.121565	2.154183	2.861907	0.9737895	2.237124	2.716848	0.0000000
[12,]	3.145472	3.794390	1.6243988	2.322525	3.159238	3.855438	2.857090	2.5356206	2.980539	3.709491	2.4505601
[13,]	3.162731	3.809159	1.7504261	2.790031	3.554885	3.786907	2.934949	3.3473126	3.024813	3.065013	3.2644812
[14,]	2.625461	2.860043	3.0788973	2.971385	2.691750	2.156437	3.376076	1.5813686	2.382823	3.131761	1.6100279
[15,]	2.549729	2.572857	3.0094180	2.863642	2.424428	2.102463	3.221387	1.5956402	2.440654	3.098592	1.7607312
[16,]	2.832654	2.794495	3.5752839	2.396703	2.243191	2.740605	2.964051	1.4501666	3.261769	3.147265	1.7699373
[17,]	3.532624	3.342450	2.3923378	1.794794	2.480112	2.941317	3.083831	2.2275800	2.314137	2.989182	1.6966413
[18,]	3.646303	3.270660	2.7337946	2.066649	1.678449	2.076762	2.633509	1.1588054	2.255311	2.701663	0.5951859
[19,]	2.674676	3.017946	1.6629353	1.660176	2.516298	2.918570	3.139241	2.0609765	2.080537	2.884732	1.4843861
[20,]	4.000000	4.000000	2.0474725	2.938142	3.505675	3.694274	2.500727	1.9416935	3.285807	3.041210	1.9590059

2.5. Distancia de Karl Pearson:

Distancia de Pearson:

La distancia de Karl Pearson entre los elementos i y j respecto de las variables cuantitativas X_1, \dots, X_p es:

$$\delta^2(i, j)_{Pearson} = \sum_{k=1}^p \frac{(x_{ik} - x_{jk})^2}{s_k^2} = (x_i - x_j)^t \cdot S_0^{-1} \cdot (x_i - x_j)$$
$$\delta(i, j)_{Pearson} = \sqrt{\sum_{k=1}^p \frac{(x_{ik} - x_{jk})^2}{s_k^2}} = \sqrt{(x_i - x_j)^t \cdot S_0^{-1} \cdot (x_i - x_j)}$$

Donde:

$$S_0 = \text{diag}(s_1^2, \dots, s_p^2)$$

s_k^2 es la varianza de X_k

Observación:

Con la distancia de Karl Pearson el peso que se atribuye a la diferencia entre individuos respecto de una variable es mayor cuanto menor sea la dispersión de dicha variable, y viceversa.

2.5.1. Inconvenientes

- 1) **Presupone** que las **variables** son **incorreladas** y con **varianza unidad**.

Aunque **si** es **invariante frente a cambios de escala** (cambios de unidades de medida) de las variables.

2.5.2. Aplicación en R: Distancia de Pearson

Programamos la distancia de Pearson:

```
1 Dist_Pearson <- function(i,j,  Matriz_Datos_Cuantitativos){
2
3   Matriz_Datos_Cuantitativos=as.matrix(Matriz_Datos_
4     Cuantitativos)
5
6   Dist_Pearson = sum( ((Matriz_Datos_Cuantitativos[i,] -
7     Matriz_Datos_Cuantitativos[j,])^2)/diag(cov(Matriz_Datos_
8     Cuantitativos)) )
9
10  return(sqrt(Dist_Pearson) )
11 }
```

```
1 Dist_Pearson(1,2, Datos_Cuantitativos)
```

```
[1] 0.7665315
```

```
1 Matriz_Dist_Pearson <- function( Matriz_Datos_Cuantitativos ){
2
3   Matriz_Datos_Cuantitativos=as.matrix(Matriz_Datos_
4     Cuantitativos)
5
6   M<-matrix(NA, ncol =dim(Matriz_Datos_Cuantitativos)[1] ,
7     nrow=dim(Matriz_Datos_Cuantitativos)[1] )
8
9   for(i in 1:dim(Matriz_Datos_Cuantitativos)[1] ){
10     for(j in 1:dim(Matriz_Datos_Cuantitativos)[1]){
11
12       M[i,j]=Dist_Pearson(i,j,  Matriz_Datos_Cuantitativos)
13     }
14   }
15   return(M)
16 }
```



```
1 Matriz_Dist_Pearson(Datos_Cuantitativos)
```

	[,1]	[,2]	[,3]	[,4]	[,5]	[,6]	[,7]	[,8]	[,9]	[,10]	[,11]
[1,]	0.0000000	0.7665315	4.1340453	2.587439	2.4759983	2.046861	3.356715	4.289427	2.3171951	1.7050413	3.6557673
[2,]	0.7665315	0.0000000	4.7135132	3.138238	2.5194692	1.905826	3.691722	4.720045	2.6496115	1.9346491	4.0612662
[3,]	4.1340453	4.7135132	0.0000000	2.816488	3.6794116	3.841170	3.662471	2.585239	2.4183247	3.2052753	2.3328535
[4,]	2.5874392	3.1382383	2.8164877	0.000000	2.5399572	3.074064	3.684258	2.800882	1.9578628	1.8641488	2.0336230
[5,]	2.4759983	2.5194692	3.6794116	2.539957	0.0000000	1.485892	2.706140	2.709763	1.6959644	1.1766895	2.0915832
[6,]	2.0468613	1.9058262	3.8411704	3.074064	1.4858920	0.000000	3.302696	3.801788	1.5477077	1.2207653	3.0946160
[7,]	3.3567152	3.6917223	3.6624705	3.684258	2.7061398	3.302696	0.000000	2.695445	3.1680046	3.0770959	2.9580385
[8,]	4.2894271	4.7200452	2.5852385	2.800882	2.7097627	3.801788	2.695445	0.000000	2.8224770	3.0701196	1.0171158
[9,]	2.3171951	2.6496115	2.4183247	1.957863	1.6959644	1.547708	3.168005	2.822477	0.0000000	0.9359033	1.9928768
[10,]	1.7050413	1.9346491	3.2052753	1.864149	1.1766895	1.220765	3.077096	3.070120	0.9359033	0.0000000	2.2563973
[11,]	3.6557673	4.0612662	2.3328535	2.033623	2.0915832	3.094616	2.958038	1.017116	1.9928768	2.2563973	0.0000000
[12,]	2.7867500	3.3744198	1.4572629	1.548948	2.6129697	2.772253	3.186149	2.488662	1.3105649	1.8998578	1.8405082
[13,]	2.0548678	2.6869638	2.0965568	1.815286	2.5162452	2.402426	2.868040	2.992665	1.3339621	1.6686987	2.4165236
[14,]	3.6245343	3.9470909	1.9037220	3.176325	2.5572597	2.490394	3.044949	2.587081	1.6186860	2.4046784	2.1835779
[15,]	4.1652453	4.4309943	2.2800319	3.743496	2.8936608	2.838937	3.298389	2.795013	2.1688127	2.9102550	2.5193636
[16,]	3.9326942	4.2954881	4.1610051	2.674489	2.7830991	4.134922	3.026202	2.156325	3.5606477	3.2181157	2.2554527
[17,]	4.1615643	4.5420991	3.8562159	2.525047	4.3666763	4.360422	6.026722	4.755582	3.2989014	3.4876801	3.8572228
[18,]	3.5240518	3.8086887	2.9088266	2.223643	1.5709455	2.743698	2.975889	1.425848	1.9540596	2.0163476	0.7075314
[19,]	3.1419491	3.5237481	2.4249575	1.376430	2.0462608	2.648189	3.660258	2.247800	1.3814848	1.6700737	1.2427113
[20,]	4.2169611	4.8793074	1.7659945	2.669354	3.8176460	4.445071	3.102504	2.049031	3.1543881	3.5604494	2.2642817

2.6. Distancia de Mahalanobis:

Distancia de Mahalanobis:

La distancia de Mahalanobis entre los elementos i y j respecto de las variables cuantitativas X_1, \dots, X_p es:

$$\delta^2(i, j)_{Maha} = (x_i - x_j)^t \cdot S^{-1} \cdot (x_i - x_j)$$

$$\delta(i, j)_{Maha} = \sqrt{(x_i - x_j)^t \cdot S^{-1} \cdot (x_i - x_j)}$$

Donde:

S es la matriz de covarianzas de la matriz de datos $X = (X_1, \dots, X_p)$

2.6.1. Ventajas:

La distancia de Mahalanobis es adecuada como medida de discrepancia entre datos por las siguientes razones:

- 1) Es **invariante frente a transformaciones lineales** de las variables
- 2) **Tiene en cuenta las correlaciones entre las variables**. Por ejemplo, no aumenta por el hecho de aumentar el número de variables observadas, sino que solo aumentará cuando las nuevas variables no sean redundantes respecto de la información aportada por las anteriores.

Observación:

- 1) La distancia euclídea coincide con la de Mahalanobis cuando $S = I$
- 2) La distancia de Karl Pearson coincide con la de Mahalanobis cuando $S = \text{diag}(s_1^2, \dots, s_p^2)$

2.6.2. Aplicación en R: Distancia de Mahalanobis

Programamos la distancia de Mahalanobis:

```
1 Dist_Mahalanobis <- function(i,j, Matriz_Datos_Cuantitativos
  ){
2
3 Matriz_Datos_Cuantitativos=as.matrix(Matriz_Datos_
  Cuantitativos)
4
5 Dist_Mahalanobis = t( Matriz_Datos_Cuantitativos[i,] -
  Matriz_Datos_Cuantitativos[j,] ) %*% solve(cov(Matriz_
  Datos_Cuantitativos)) %*% ( Matriz_Datos_Cuantitativos[i,]
  - Matriz_Datos_Cuantitativos[j,] )
6
7 Dist_Mahalanobis <- sqrt(Dist_Mahalanobis)
8
9 return( Dist_Mahalanobis )
10 }
```

```
1 Dist_Mahalanobis(1,2, Datos_Cuantitativos)
```

```
      [,1]
[1,] 0.7384377
```

Programamos la matriz de distancias de Mahalanobis:

```
1 Matriz_Dist_Mahalanobis <- function( Matriz_Datos_
  Cuantitativos ){
2
3 Matriz_Datos_Cuantitativos=as.matrix(Matriz_Datos_
  Cuantitativos)
4
5 M<-matrix(NA, ncol =dim(Matriz_Datos_Cuantitativos)[1] ,
  nrow=dim(Matriz_Datos_Cuantitativos)[1] )
6
7 for(i in 1:dim(Matriz_Datos_Cuantitativos)[1] ){
8   for(j in 1:dim(Matriz_Datos_Cuantitativos)[1]){
9
10    M[i,j]=Dist_Mahalanobis(i,j, Matriz_Datos_Cuantitativos)
11
12   }
13 }
14 return(M)
15 }
```

Matriz_Dist_Mahalanobis(Datos_Cuantitativos)

	[,1]	[,2]	[,3]	[,4]	[,5]	[,6]	[,7]	[,8]	[,9]	[,10]	[,11]
[1,]	0.0000000	0.7384377	3.9788574	2.444996	2.5692943	2.205804	3.2640580	4.1150559	2.3138245	1.7166677	3.5237623
[2,]	0.7384377	0.0000000	4.4920546	2.941129	2.5206119	2.015150	3.5259949	4.4561551	2.5609024	1.8548342	3.8386520
[3,]	3.9788574	4.4920546	0.0000000	3.007805	3.6555102	3.642408	3.4906740	2.6830491	2.3215174	3.1234319	2.4672874
[4,]	2.4449958	2.9411288	3.0078051	0.000000	2.6208769	3.143340	3.6512263	2.8323810	2.1325193	1.8961685	2.1342843
[5,]	2.5692943	2.5206119	3.6555102	2.620877	0.0000000	1.498364	2.6181668	2.5103723	1.7286650	1.2089587	1.9445687
[6,]	2.2058040	2.0151496	3.6424076	3.143340	1.4983639	0.000000	3.0950975	3.5511155	1.4654074	1.2585501	2.9109903
[7,]	3.2640580	3.5259949	3.4906740	3.651226	2.6181668	3.095097	0.0000000	2.5718018	2.9796743	2.9201241	2.8268707
[8,]	4.1150559	4.4561551	2.6830491	2.832381	2.5103723	3.551116	2.5718018	0.0000000	2.6836014	2.8760331	0.9569153
[9,]	2.3138245	2.5609024	2.3215174	2.132519	1.7286650	1.465407	2.9796743	2.6836014	0.0000000	0.9597218	1.9323146
[10,]	1.7166677	1.8548342	3.1234319	1.896168	1.2089587	1.258550	2.9201241	2.8760331	0.9597218	0.0000000	2.1141826
[11,]	3.5237623	3.8386520	2.4672874	2.134284	1.9445687	2.910990	2.8268707	0.9569153	1.9323146	2.1141826	0.0000000
[12,]	2.6356384	3.1644191	1.4644753	1.708877	2.6334132	2.670792	3.0387803	2.4877365	1.2904842	1.8428050	1.9102473
[13,]	1.9781281	2.5529312	2.0205466	1.952399	2.6254593	2.398479	2.7758344	2.9811526	1.3772200	1.7054755	2.4654917
[14,]	3.7361456	3.9659210	1.9160149	3.532411	2.6866535	2.409838	2.9593610	2.6666633	1.7154982	2.5380309	2.3668902
[15,]	4.3431665	4.5164398	2.3771749	4.158321	3.0739307	2.810234	3.2793781	2.9540955	2.3263366	3.1032584	2.7745376
[16,]	3.8613532	4.1401385	4.4025231	2.645047	2.8093890	4.158190	3.2208554	2.3209227	3.6569616	3.2017312	2.3673278
[17,]	3.9236804	4.2783884	3.9117227	2.386881	4.3080899	4.333959	5.8130906	4.6433198	3.3290392	3.4035894	3.8067194
[18,]	3.4799704	3.6658304	3.0410859	2.367370	1.4574909	2.627328	2.8895462	1.3420813	1.9777208	1.9545562	0.7011910
[19,]	3.0106374	3.3130806	2.5215480	1.483720	1.9527302	2.537933	3.4881144	2.1307603	1.3975836	1.5596548	1.1873742
[20,]	3.9171206	4.5302385	1.8009551	2.603486	3.7072797	4.213938	2.9733733	2.1546965	2.9888824	3.3538678	2.3021805

3. DISTANCIAS CON VARIABLES CATEGORICAS:

3.1. Similaridad:

Se trata de un concepto dual al de distancia que expresa la proximidad o semejanza entre dos elementos.

Similaridad:

Dado un conjunto de elementos \mathcal{E} , se denomina similaridad a toda aplicación

$s : \mathcal{E} \times \mathcal{E} \rightarrow \mathbb{R}$ tal que:

- 1) $0 \leq s_{ij} \leq 1$
- 2) $s_{ii} = 1$
- 3) $s_{ij} = s_{ji}$

3.2. Matriz de Similaridades:

Matriz de Similaridad:

$$S = \begin{pmatrix} s_{11} & s_{12} & \dots & s_{1n} \\ s_{21} & s_{22} & \dots & s_{2n} \\ \dots & \dots & \dots & \dots \\ s_{n1} & s_{n2} & \dots & s_{nn} \end{pmatrix}$$

Con $s_{ii} = 1$ y $s_{ij} = s_{ji}$

3.3. Pasar de una similaridad a una distancia:

Pasar de una similaridad a una distancia:

Las siguientes transformaciones permiten pasar de una medida de similaridad a una distancia:

1)

$$\delta_{ij} = 1 - s_{ij}$$

2)

$$\delta_{ij} = \sqrt{1 - s_{ij}}$$

3) Transformación de Gower:

$$\delta_{ij}^2 = s_{ii} + s_{jj} - 2 \cdot s_{ij}$$

3.4. Similaridades con variables categoricas binarias:

Sean X_1, \dots, X_p variables categoricas **binarias** ($X_j \in \{0, 1\}$)

Los principales coeficientes de similaridad entre dos individuos/elementos respecto de variables binarias se suelen calcular a partir de los siguientes parametros:

a_{ij} = nº de variables con respuesta 1 en ambos elementos i y j

b_{ij} = nº de variables con respuesta 0 en el elemento i y respuesta 1 en el j

c_{ij} = nº de variables con respuesta 1 en el elemento i y respuesta 0 en el j

d_{ij} = nº de variables con respuesta 0 en ambos elementos i y j

Observación:

$$a_{ij} + b_{ij} + c_{ij} + d_{ij} = p$$

3.4.1. Matrices con los parametros a, b, c y d:

Dada una matriz de datos $X = (X_1, \dots, X_p)$ de tamaño $n \times p$ de variables categoricas binarias, entonces:

Matrices con los parametros :

$$a = X \cdot X^t$$

$$b = (\vec{1}_{n \times p} - X) \cdot X^t$$

$$c = b^t$$

$$d = (\vec{1}_{n \times p} - X) \cdot (\vec{1}_{n \times p} - X)^t$$

Son las matrices que contienen a los parametros a_{ij} , b_{ij} , c_{ij} y d_{ij} , respectivamente.

3.4.2. Aplicación en R:

```
1 Datos_Binarios <- Datos_Mixtos%>% select(5:7)
```

A tibble: 50 x 3

X5 <dbl>	X6 <dbl>	X7 <dbl>
0	1	0
1	1	1
1	0	0
1	1	1
1	1	0
1	1	1
1	0	0
0	0	0
0	0	0
1	0	0
0	1	0
1	0	1
0	1	0
1	1	1
0	1	1

1-15 of 50 rows Previous 1 2 Next

Obtencion de las matrices con los parametros a, b, c y d:

```
1 Datos_Binarios <- as.matrix(Datos_Binarios)
2
3 a = Datos_Binarios %*% t(Datos_Binarios)
4
5 unos<- rep(1, dim(Datos_Binarios)[2])
6
7 Matriz_Unos<- matrix( rep(unos, dim(Datos_Binarios)[1]), ncol=
8   dim(Datos_Binarios)[2]) #Matriz de unos de tamaño nxp
9
10 b = (Matriz_Unos-Datos_Binarios)%*%t(Datos_Binarios)
11
12 c = t(b)
13
14 d = (Matriz_Unos - Datos_Binarios)%*%t(Matriz_Unos - Datos_
15   Binarios)
```

3.4.3. Coeficiente de Sokal: (Simple matching coefficient)

Coeficiente de Sokal:

El coeficiente de similaridad de Sokal entre los elementos/individuos i y j respecto de las variables binarias X_1, \dots, X_p es:

$$S(i, j)_{Sokal} = \frac{a_{ij} + d_{ij}}{a_{ij} + b_{ij} + c_{ij} + d_{ij}} = \frac{a_{ij} + d_{ij}}{p}$$

Distancia de Sokal:

Distancia de Sokal:

Obtenemos la distancia de Sokal como:

$$\delta(i, j)_{Sokal} = \sqrt{S(i, i)_{Sokal} + S(j, j)_{Sokal} - 2 \cdot S(i, j)_{Sokal}}$$

Aplicación en R: Coeficiente de Similitud de Sokal:

Programamos el coeficiente de similitud de Sokal:

```
1 Similaridad_Sokal <- function(i,j, Matriz_Datos_Binarios){
2
3   Matriz_Datos_Binarios=as.matrix(Matriz_Datos_Binarios)
4
5
6   a= Matriz_Datos_Binarios %*% t(Matriz_Datos_Binarios)
7
8   unos<- rep(1, dim(Matriz_Datos_Binarios)[2])
9
10  Matriz_Unos<- matrix( rep(unos, dim(Matriz_Datos_Binarios)[1
11    ]), ncol=dim(Matriz_Datos_Binarios)[2])
12  #Matriz de unos de tamaño nxp
13
14  b=(Matriz_Unos-Matriz_Datos_Binarios)%*%t(Matriz_Datos_
15    Binarios)
16
17  c= t(b)
18
19  d= (Matriz_Unos - Matriz_Datos_Binarios)%*%t(Matriz_Unos -
20    Matriz_Datos_Binarios)
21
22  Similaridad_Sokal = (a[i,j] + d[i,j]) / dim(Matriz_Datos_
23    Binarios)[2]
24
25  return(Similaridad_Sokal)
26 }
```

```
1 Similaridad_Sokal(1, 2, Datos_Binarios)
```

```
[1] 0.3333333
```

```
1 Similaridad_Sokal(7,8, Datos_Binarios)
```

```
[1] 0.6666667
```

Programamos la matriz de similitudes de Sokal:

```

1 Matriz_Similaridad_Sokal <- function( Matriz_Datos_
  Cuantitativos ){
2
3   Matriz_Datos_Binarios=as.matrix(Matriz_Datos_Binarios)
4
5   M<-matrix(NA, ncol =dim(Matriz_Datos_Cuantitativos)[1] ,
6             nrow=dim(Matriz_Datos_Cuantitativos)[1] )
7
8   for(i in 1:dim(Matriz_Datos_Cuantitativos)[1] ){
9     for(j in 1:dim(Matriz_Datos_Cuantitativos)[1]){
10
11      M[i,j]=Similaridad_Sokal(i,j, Matriz_Datos_Cuantitativos)
12
13     }
14   }
15   return(M)
16 }

```

```

1 Matriz_Similaridad_Sokal(Datos_Binarios)

```

	[,1]	[,2]	[,3]	[,4]	[,5]	[,6]	[,7]	[,8]	[,9]	[,10]	[,11]
[1,]	1.0000000	0.3333333	0.3333333	0.3333333	0.6666667	0.3333333	0.3333333	0.6666667	0.6666667	0.3333333	1.0000000
[2,]	0.3333333	1.0000000	0.3333333	1.0000000	0.6666667	1.0000000	0.3333333	0.0000000	0.0000000	0.3333333	0.3333333
[3,]	0.3333333	0.3333333	1.0000000	0.3333333	0.6666667	0.3333333	1.0000000	0.6666667	0.6666667	1.0000000	0.3333333
[4,]	0.3333333	1.0000000	0.3333333	1.0000000	0.6666667	1.0000000	0.3333333	0.0000000	0.0000000	0.3333333	0.3333333
[5,]	0.6666667	0.6666667	0.6666667	0.6666667	1.0000000	0.6666667	0.6666667	0.3333333	0.3333333	0.6666667	0.6666667
[6,]	0.3333333	1.0000000	0.3333333	1.0000000	0.6666667	1.0000000	0.3333333	0.0000000	0.0000000	0.3333333	0.3333333
[7,]	0.3333333	0.3333333	1.0000000	0.3333333	0.6666667	0.3333333	1.0000000	0.6666667	0.6666667	1.0000000	0.3333333
[8,]	0.6666667	0.0000000	0.6666667	0.0000000	0.3333333	0.0000000	0.6666667	1.0000000	1.0000000	0.6666667	0.6666667
[9,]	0.6666667	0.0000000	0.6666667	0.0000000	0.3333333	0.0000000	0.6666667	1.0000000	1.0000000	0.6666667	0.6666667
[10,]	0.3333333	0.3333333	1.0000000	0.3333333	0.6666667	0.3333333	1.0000000	0.6666667	0.6666667	1.0000000	0.3333333
[11,]	1.0000000	0.3333333	0.3333333	0.3333333	0.6666667	0.3333333	0.3333333	0.6666667	0.6666667	0.3333333	1.0000000
[12,]	0.0000000	0.6666667	0.6666667	0.6666667	0.3333333	0.6666667	0.6666667	0.3333333	0.3333333	0.6666667	0.0000000
[13,]	1.0000000	0.3333333	0.3333333	0.3333333	0.6666667	0.3333333	0.3333333	0.6666667	0.6666667	0.3333333	1.0000000
[14,]	0.3333333	1.0000000	0.3333333	1.0000000	0.6666667	1.0000000	0.3333333	0.0000000	0.0000000	0.3333333	0.3333333
[15,]	0.6666667	0.6666667	0.0000000	0.6666667	0.3333333	0.6666667	0.0000000	0.3333333	0.3333333	0.0000000	0.6666667
[16,]	1.0000000	0.3333333	0.3333333	0.3333333	0.6666667	0.3333333	0.3333333	0.6666667	0.6666667	0.3333333	1.0000000
[17,]	1.0000000	0.3333333	0.3333333	0.3333333	0.6666667	0.3333333	0.3333333	0.6666667	0.6666667	0.3333333	1.0000000
[18,]	0.3333333	1.0000000	0.3333333	1.0000000	0.6666667	1.0000000	0.3333333	0.0000000	0.0000000	0.3333333	0.3333333
[19,]	0.6666667	0.0000000	0.6666667	0.0000000	0.3333333	0.0000000	0.6666667	1.0000000	1.0000000	0.6666667	0.6666667
[20,]	0.3333333	0.3333333	0.3333333	0.3333333	0.0000000	0.3333333	0.3333333	0.6666667	0.6666667	0.3333333	0.3333333

En este caso pasamos de similaridad a distancia usando la transformacion:

$$\delta(i, j)_{Sokal} = \sqrt{S(i, i)_{Sokal} + S(j, j)_{Sokal} - 2 \cdot S(i, j)_{Sokal}}$$

```
1 Dist_Sokal <- function(i,j, Matriz_Datos_Binarios){
2
3 Matriz_Datos_Binarios=as.matrix(Matriz_Datos_Binarios)
4
5 Dist_Sokal = sqrt( Similaridad_Sokal(i,i, Matriz_Datos_
6 Binarios) + Similaridad_Sokal(j,j, Matriz_Datos_Binarios)
7 - 2*Similaridad_Sokal(i,j, Matriz_Datos_Binarios) )
8
9 return( Dist_Sokal )
10 }
```

```
1 Dist_Sokal(1, 2, Matriz_Datos_Binarios = Datos_Binarios)
```

```
[1] 1.154701
```

```
1 Matriz_Distancias_Sokal <- function( Matriz_Datos_Binarios ){
2
3 Matriz_Datos_Binarios=as.matrix(Matriz_Datos_Binarios)
4
5 M<-matrix(NA, ncol =dim(Matriz_Datos_Binarios)[1] , nrow=dim
6 (Matriz_Datos_Binarios)[1] )
7
8 for(i in 1:dim(Matriz_Datos_Binarios)[1] ){
9 for(j in 1:dim(Matriz_Datos_Binarios)[1]){
10
11 M[i,j]=Dist_Sokal(i,j, Matriz_Datos_Binarios)
12
13 }
14 }
15 return(M)
16 }
```

1 Matriz_Distancias_Sokal(Datos_Binarios)

	[,1]	[,2]	[,3]	[,4]	[,5]	[,6]	[,7]	[,8]	[,9]	[,10]	[,11]
[1,]	0.0000000	1.1547005	1.1547005	1.1547005	0.8164966	1.1547005	1.1547005	0.8164966	0.8164966	1.1547005	0.0000000
[2,]	1.1547005	0.0000000	1.1547005	0.0000000	0.8164966	0.0000000	1.1547005	1.4142136	1.4142136	1.1547005	1.1547005
[3,]	1.1547005	1.1547005	0.0000000	1.1547005	0.8164966	1.1547005	0.0000000	0.8164966	0.8164966	0.0000000	1.1547005
[4,]	1.1547005	0.0000000	1.1547005	0.0000000	0.8164966	0.0000000	1.1547005	1.4142136	1.4142136	1.1547005	1.1547005
[5,]	0.8164966	0.8164966	0.8164966	0.8164966	0.0000000	0.8164966	0.8164966	1.1547005	1.1547005	0.8164966	0.8164966
[6,]	1.1547005	0.0000000	1.1547005	0.0000000	0.8164966	0.0000000	1.1547005	1.4142136	1.4142136	1.1547005	1.1547005
[7,]	1.1547005	1.1547005	0.0000000	1.1547005	0.8164966	1.1547005	0.0000000	0.8164966	0.8164966	0.0000000	1.1547005
[8,]	0.8164966	1.4142136	0.8164966	1.4142136	1.1547005	1.4142136	0.8164966	0.0000000	0.0000000	0.8164966	0.8164966
[9,]	0.8164966	1.4142136	0.8164966	1.4142136	1.1547005	1.4142136	0.8164966	0.0000000	0.0000000	0.8164966	0.8164966
[10,]	1.1547005	1.1547005	0.0000000	1.1547005	0.8164966	1.1547005	0.0000000	0.8164966	0.8164966	0.0000000	1.1547005
[11,]	0.0000000	1.1547005	1.1547005	1.1547005	0.8164966	1.1547005	1.1547005	0.8164966	0.8164966	1.1547005	0.0000000
[12,]	1.4142136	0.8164966	0.8164966	0.8164966	1.1547005	0.8164966	0.8164966	1.1547005	1.1547005	0.8164966	1.4142136
[13,]	0.0000000	1.1547005	1.1547005	1.1547005	0.8164966	1.1547005	1.1547005	0.8164966	0.8164966	1.1547005	0.0000000
[14,]	1.1547005	0.0000000	1.1547005	0.0000000	0.8164966	0.0000000	1.1547005	1.4142136	1.4142136	1.1547005	1.1547005
[15,]	0.8164966	0.8164966	1.4142136	0.8164966	1.1547005	0.8164966	1.4142136	1.1547005	1.1547005	1.4142136	0.8164966
[16,]	0.0000000	1.1547005	1.1547005	1.1547005	0.8164966	1.1547005	1.1547005	0.8164966	0.8164966	1.1547005	0.0000000
[17,]	0.0000000	1.1547005	1.1547005	1.1547005	0.8164966	1.1547005	1.1547005	0.8164966	0.8164966	1.1547005	0.0000000
[18,]	1.1547005	0.0000000	1.1547005	0.0000000	0.8164966	0.0000000	1.1547005	1.4142136	1.4142136	1.1547005	1.1547005
[19,]	0.8164966	1.4142136	0.8164966	1.4142136	1.1547005	1.4142136	0.8164966	0.0000000	0.0000000	0.8164966	0.8164966
[20,]	1.1547005	1.1547005	1.1547005	1.1547005	1.4142136	1.1547005	1.1547005	0.8164966	0.8164966	1.1547005	1.1547005

3.4.4. Coeficiente de Jaccard:

Coeficiente de Jaccard:

El coeficiente de similaridad de Jaccard entre los elementos/individuos i y j respecto de las variables binarias X_1, \dots, X_p es:

$$S(i, j)_{Jaccard} = \frac{a_{ij}}{a_{ij} + b_{ij} + c_{ij}}$$

Distancia de Jaccard:

Distancia de Jaccard:

Obtenemos la distancia de Jaccard como:

$$\delta(i, j)_{Jaccard} = \sqrt{S(i, i)_{Jaccard} + S(j, j)_{Jaccard} - 2 \cdot S(i, j)_{Jaccard}}$$

3.4.5. Aplicación en R: Coeficiente de Similitud de Jaccard:

Programamos el coeficiente de similitud de Jaccard:

```
1 Similaridad_Jaccard<- function(i,j, Matriz_Datos_Binarios){
2
3   Matriz_Datos_Binarios=as.matrix(Matriz_Datos_Binarios)
4
5   a= Matriz_Datos_Binarios %*% t(Matriz_Datos_Binarios)
6
7   unos<- rep(1, dim(Matriz_Datos_Binarios)[2])
8
9   Matriz_Unos<- matrix( rep(unos, dim(Matriz_Datos_Binarios)[1
10     ]), ncol=dim(Matriz_Datos_Binarios)[2])
11   #Matriz de unos de tamaño nxp
12
13   b=(Matriz_Unos-Matriz_Datos_Binarios)%*%t(Matriz_Datos_
14     Binarios)
15
16   c= t(b)
17
18   d= (Matriz_Unos - Matriz_Datos_Binarios)%*%t(Matriz_Unos -
19     Matriz_Datos_Binarios)
20
21   Similaridad_Jaccard = a[i,j] / (a[i,j] + b[i,j] + c[i,j])
22
23   return(Similaridad_Jaccard)
24 }
```

```
1 Similaridad_Jaccard(1,2, Datos_Binarios)
```

```
[1] 0.3333333
```

```
1 Similaridad_Jaccard(9,8, Datos_Binarios)
```

```
[1] 0
```


Programamos la matriz de similitudes de Jaccard:

```

1  Matriz_Similaridad_Jaccard <- function( Matriz_Datos_
    Cuantitativos ){
2
3  Matriz_Datos_Binarios=as.matrix(Matriz_Datos_Binarios)
4
5
6  M<-matrix(NA, ncol =dim(Matriz_Datos_Cuantitativos)[1] ,
    nrow=dim(Matriz_Datos_Cuantitativos)[1] )
7
8  for(i in 1:dim(Matriz_Datos_Cuantitativos)[1] ){
9    for(j in 1:dim(Matriz_Datos_Cuantitativos)[1]){
10
11    M[i,j]=Similaridad_Jaccard(i,j, Matriz_Datos_Cuantitativos)
12
13    }
14  }
15  return(M)
16 }

```

```

1  Matriz_Similaridad_Jaccard(Datos_Binarios)

```

	[,1]	[,2]	[,3]	[,4]	[,5]	[,6]	[,7]	[,8]	[,9]	[,10]	[,11]
[1,]	1.0000000	0.3333333	0.0000000	0.3333333	0.5000000	0.3333333	0.0000000	0	0	0.0000000	1.0000000
[2,]	0.3333333	1.0000000	0.3333333	1.0000000	0.6666667	1.0000000	0.3333333	0	0	0.3333333	0.3333333
[3,]	0.0000000	0.3333333	1.0000000	0.3333333	0.5000000	0.3333333	1.0000000	0	0	1.0000000	0.0000000
[4,]	0.3333333	1.0000000	0.3333333	1.0000000	0.6666667	1.0000000	0.3333333	0	0	0.3333333	0.3333333
[5,]	0.5000000	0.6666667	0.5000000	0.6666667	1.0000000	0.6666667	0.5000000	0	0	0.5000000	0.5000000
[6,]	0.3333333	1.0000000	0.3333333	1.0000000	0.6666667	1.0000000	0.3333333	0	0	0.3333333	0.3333333
[7,]	0.0000000	0.3333333	1.0000000	0.3333333	0.5000000	0.3333333	1.0000000	0	0	1.0000000	0.0000000
[8,]	0.0000000	0.0000000	0.0000000	0.0000000	0.0000000	0.0000000	0.0000000	NaN	NaN	0.0000000	0.0000000
[9,]	0.0000000	0.0000000	0.0000000	0.0000000	0.0000000	0.0000000	0.0000000	NaN	NaN	0.0000000	0.0000000
[10,]	0.0000000	0.3333333	1.0000000	0.3333333	0.5000000	0.3333333	1.0000000	0	0	1.0000000	0.0000000
[11,]	1.0000000	0.3333333	0.0000000	0.3333333	0.5000000	0.3333333	0.0000000	0	0	0.0000000	1.0000000
[12,]	0.0000000	0.6666667	0.5000000	0.6666667	0.3333333	0.6666667	0.5000000	0	0	0.5000000	0.0000000
[13,]	1.0000000	0.3333333	0.0000000	0.3333333	0.5000000	0.3333333	0.0000000	0	0	0.0000000	1.0000000
[14,]	0.3333333	1.0000000	0.3333333	1.0000000	0.6666667	1.0000000	0.3333333	0	0	0.3333333	0.3333333
[15,]	0.5000000	0.6666667	0.0000000	0.6666667	0.3333333	0.6666667	0.0000000	0	0	0.0000000	0.5000000
[16,]	1.0000000	0.3333333	0.0000000	0.3333333	0.5000000	0.3333333	0.0000000	0	0	0.0000000	1.0000000
[17,]	1.0000000	0.3333333	0.0000000	0.3333333	0.5000000	0.3333333	0.0000000	0	0	0.0000000	1.0000000
[18,]	0.3333333	1.0000000	0.3333333	1.0000000	0.6666667	1.0000000	0.3333333	0	0	0.3333333	0.3333333
[19,]	0.0000000	0.0000000	0.0000000	0.0000000	0.0000000	0.0000000	0.0000000	NaN	NaN	0.0000000	0.0000000
[20,]	0.0000000	0.3333333	0.0000000	0.3333333	0.0000000	0.3333333	0.0000000	0	0	0.0000000	0.0000000

En este caso pasamos de similaridad a distancia usando la transformacion:

$$\delta(i, j)_{Jaccard} = \sqrt{S(i, i)_{Jaccard} + S(j, j)_{Jaccard} - 2 \cdot S(i, j)_{Jaccard}}$$

```
1 Dist_Jaccard <- function(i,j, Matriz_Datos_Binarios){
2
3 Matriz_Datos_Binarios=as.matrix(Matriz_Datos_Binarios)
4
5 Dist_Jaccard = sqrt( Similaridad_Jaccard(i,i, Matriz_Datos_
  Binarios) + Similaridad_Jaccard(j,j, Matriz_Datos_
  Binarios) - 2*Similaridad_Jaccard(i,j, Matriz_Datos_
  Binarios) )
6
7 return( Dist_Jaccard )
8 }
```

```
1 Dist_Jaccard(1,2, Datos_Binarios)
```

```
[1] 1.154701
```

```
1 Matriz_Distancias_Jaccard <- function( Matriz_Datos_Binarios )
2 {
3 Matriz_Datos_Binarios=as.matrix(Matriz_Datos_Binarios)
4
5
6 M<-matrix(NA, ncol =dim(Matriz_Datos_Binarios)[1] , nrow=dim
  (Matriz_Datos_Binarios)[1] )
7
8 for(i in 1:dim(Matriz_Datos_Binarios)[1] ){
9   for(j in 1:dim(Matriz_Datos_Binarios)[1]){
10
11 M[i,j]=Dist_Jaccard(i,j, Matriz_Datos_Binarios)
12
13   }
14 }
15 return(M)
16 }
```



```
1 Matriz_Distancias_Jaccard(Datos_Binarios)
```

	[,1]	[,2]	[,3]	[,4]	[,5]	[,6]	[,7]	[,8]	[,9]	[,10]	[,11]	[,12]
[1,]	0.000000	1.1547005	1.414214	1.1547005	1.0000000	1.1547005	1.414214	NaN	NaN	1.414214	0.000000	1.4142136
[2,]	1.154701	0.0000000	1.154701	0.0000000	0.8164966	0.0000000	1.154701	NaN	NaN	1.154701	1.154701	0.8164966
[3,]	1.414214	1.1547005	0.000000	1.1547005	1.0000000	1.1547005	0.000000	NaN	NaN	0.000000	1.414214	1.0000000
[4,]	1.154701	0.0000000	1.154701	0.0000000	0.8164966	0.0000000	1.154701	NaN	NaN	1.154701	1.154701	0.8164966
[5,]	1.000000	0.8164966	1.000000	0.8164966	0.0000000	0.8164966	1.000000	NaN	NaN	1.000000	1.000000	1.1547005
[6,]	1.154701	0.0000000	1.154701	0.0000000	0.8164966	0.0000000	1.154701	NaN	NaN	1.154701	1.154701	0.8164966
[7,]	1.414214	1.1547005	0.000000	1.1547005	1.0000000	1.1547005	0.000000	NaN	NaN	0.000000	1.414214	1.0000000
[8,]	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN
[9,]	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN
[10,]	1.414214	1.1547005	0.000000	1.1547005	1.0000000	1.1547005	0.000000	NaN	NaN	0.000000	1.414214	1.0000000
[11,]	0.000000	1.1547005	1.414214	1.1547005	1.0000000	1.1547005	1.414214	NaN	NaN	1.414214	0.000000	1.4142136
[12,]	1.414214	0.8164966	1.000000	0.8164966	1.1547005	0.8164966	1.000000	NaN	NaN	1.000000	1.414214	0.0000000
[13,]	0.000000	1.1547005	1.414214	1.1547005	1.0000000	1.1547005	1.414214	NaN	NaN	1.414214	0.000000	1.4142136
[14,]	1.154701	0.0000000	1.154701	0.0000000	0.8164966	0.0000000	1.154701	NaN	NaN	1.154701	1.154701	0.8164966
[15,]	1.000000	0.8164966	1.414214	0.8164966	1.1547005	0.8164966	1.414214	NaN	NaN	1.414214	1.000000	1.1547005
[16,]	0.000000	1.1547005	1.414214	1.1547005	1.0000000	1.1547005	1.414214	NaN	NaN	1.414214	0.000000	1.4142136
[17,]	0.000000	1.1547005	1.414214	1.1547005	1.0000000	1.1547005	1.414214	NaN	NaN	1.414214	0.000000	1.4142136
[18,]	1.154701	0.0000000	1.154701	0.0000000	0.8164966	0.0000000	1.154701	NaN	NaN	1.154701	1.154701	0.8164966
[19,]	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN
[20,]	1.414214	1.1547005	1.414214	1.1547005	1.4142136	1.1547005	1.414214	NaN	NaN	1.414214	1.414214	1.0000000

3.4.6. Más coeficientes de similaridad:

Coeficiente	Valores	Prop. euclídea
$S_1 \quad \frac{a}{b+c}$	$(0, \infty)$	
$S_2 \quad \frac{a}{a+b+c+d}$	$(0, 1)$	sí
$S_3 \quad \frac{a}{a+b+c}$	$(0, 1)$	sí
$S_4 \quad \frac{a+d}{a+b+c+d}$	$(0, 1)$	sí
$S_5 \quad \frac{a}{a+2(b+c)}$	$(0, 1)$	sí
$S_6 \quad \frac{a+d}{a+2(b+c)+d}$	$(0, 1)$	sí
$S_7 \quad \frac{a}{a+0.5(b+c)}$	$(0, 1)$	sí
$S_8 \quad \frac{a+d}{a+0.5(b+c)+d}$	$(0, 1)$	no
\vdots		

Coeficiente	Valores	Prop. euclídea
\vdots		
$S_9 \quad \frac{a+d-(b+c)}{a+b+c+d}$	$(-1, 1)$	sí
$S_{10} \quad \frac{1}{2} \left(\frac{a}{a+b} + \frac{a}{a+c} \right)$	$(0, 1)$	no
$S_{11} \quad \frac{1}{2} \left(\frac{a}{a+b} + \frac{a}{a+c} + \frac{d}{c+d} + \frac{d}{b+d} \right)$	$(0, 1)$	no
$S_{12} \quad \frac{a}{\sqrt{(a+b)(a+c)}}$	$(0, 1)$	sí
$S_{13} \quad \frac{ad}{\sqrt{(a+b)(a+c)(b+d)(c+d)}}$	$(0, 1)$	sí
$S_{14} \quad \frac{ad-bc}{\sqrt{(a+b)(a+c)(b+d)(c+d)}}$	$(-1, 1)$	sí
$S_{15} \quad \frac{ad-bc}{ad+bc}$	$(-1, 1)$	no

3.5. Similaridades con variables categoricas múltiples

Sean X_1, \dots, X_p variables **categoricas multiples (no binarias)** con posible distinto numero de categorias.

Los parámetros usados para construir los coeficientes de similaridad con variables categoricas multiples son:

$\alpha_{ij} = \text{n}^\circ \text{ de coincidencias entre las } p \text{ variables para ambos elementos } i \text{ y } j$

$p - \alpha_{ij} = \text{n}^\circ \text{ de no coincidencias entre las } p \text{ variables para ambos elementos } i \text{ y } j$

3.5.1. Coeficiente de Coincidencias:

La medida de similaridad mas habitual en estos casos es el coeficiente de coincidencias:

Coeficiente de Coincidencias:

El coeficiente de coincidencias entre los elementos/individuos i y j respecto de las variables categoricas múltiples (no binarias) X_1, \dots, X_p es:

$$S(i, j)_{\text{Coincidencias}} = \frac{\alpha_{ij}}{p}$$

Observación:

Cuando las variables son binarias el coeficiente de coincidencias coincide con el de Sokal, puesto que $\alpha_{ij} = a_{ij} + b_{ij}$

Distancia de Coincidencias

Distancia de Coincidencias:

Obtenemos la distancia de coincidencias:

$$\delta(i, j)_{\text{Coincidencias}} = \sqrt{S(i, i)_{\text{Coincidencias}} + S(j, j)_{\text{Coincidencias}} - 2 \cdot S(i, j)_{\text{Coincidencias}}}$$

3.5.2. Aplicación en R:

```
1 Datos_Categoricos_Multiples <- Datos_Mixtos%>% select(8:10)
```

A tibble: 50 x 3

X8 <dbl>	X9 <dbl>	X10 <dbl>
3	2	4
4	3	4
3	2	0
2	0	2
2	2	4
3	0	1
1	0	1
2	3	2
2	2	1
2	2	4
1	0	2
1	1	2
0	3	3
3	1	1
4	0	2

1-15 of 50 rows Previous 2 Next

3.5.3. Coeficiente de similitud de Coincidencias:

Primero programamos una función que nos permita obtener $\alpha_{i,j}$

```
1 alpha<- function(i,j, Matriz_Datos_Categoricos_Multiples){
2
3   X=as.matrix(Matriz_Datos_Categoricos_Multiples)
4
5   alpha=ifelse( X[i,]==X[j,] , yes = 1 , 0)
6
7   # Otra forma de hacer lo mismo, pero menos eficiente:
8
9   # alpha=rep(0, dim(Matriz_Datos_Categoricos_Multiples)[2])
10
11   # for(k in 1:dim(X)[2]){
12   # if( X[i,k]==X[j,k] ){ alpha[k]=1 } else { alpha[k]=0 }
13   # }
14
15   alpha=sum(alpha)
16
17   return(alpha)
18 }
```

```
1 alpha(1,3 , Datos_Categoricos_Multiples)
```

```
[1] 2
```

Ahora programamos el coeficiente de coincidencias:

```
1 Similaridad_Coincidencias <- function(i,j, Matriz_Datos_
2   Categoricos_Multiples){
3
4   Matriz_Datos_Categoricos_Multiples=as.matrix(Matriz_Datos_
5   Categoricos_Multiples)
6
7   Similaridad_Coincidencias = alpha(i,j, Matriz_Datos_
8   Categoricos_Multiples) / dim(Matriz_Datos_Categoricos_
9   Multiples)[2]
10
11   return(Similaridad_Coincidencias )
12 }
```

```
1 Similaridad_Coincidencias(1,3, Datos_Categoricos_Multiples)
```

```
[1] 0.6666667
```

En este caso pasamos de similaridad a distancia usando la transformacion:

$$\delta(i,j)_{Coincidencias} = \sqrt{S(i,i)_{Coincidencias} + S(j,j)_{Coincidencias} - 2 \cdot S(i,j)_{Coincidencias}}$$

```
1 Dist_Coincidencias <- function(i,j, Matriz_Datos_Categoricos
  _Multiples){
2
3 Matriz_Datos_Categoricos_Multiples=as.matrix(Matriz_Datos_
  Categoricos_Multiples)
4
5 Dist_Coincidencias = sqrt( Similaridad_Coincidencias(i,i,
  Matriz_Datos_Categoricos_Multiples) + Similaridad_
  Coincidencias(j,j, Matriz_Datos_Categoricos_Multiples) -
  2*Similaridad_Coincidencias(i,j, Matriz_Datos_Categoricos
  _Multiples) )
6
7 return(Dist_Coincidencias )
8 }
```

```
1 Dist_Coincidencias(1,3, Datos_Categoricos_Multiples)
```

```
[1] 0.8164966
```

```
1 Matriz_Similaridad_Coincidencias <- function( Matriz_Datos_
  Categoricos_Multiples ){
2
3 Matriz_Datos_Categoricos_Multiples=as.matrix(Matriz_Datos_
  Categoricos_Multiples)
4
5 M<-matrix(NA, ncol =dim(Matriz_Datos_Categoricos_Multiples)[
  1] , nrow=dim(Matriz_Datos_Categoricos_Multiples)[1] )
6
7 for(i in 1:dim(Matriz_Datos_Categoricos_Multiples)[1] ){
8   for(j in 1:dim(Matriz_Datos_Categoricos_Multiples)[1]){
9
10 M[i,j]=Similaridad_Coincidencias(i,j, Matriz_Datos_
  Categoricos_Multiples)
11 }
```

```
12     }  
13     }  
14     return(M)  
15 }
```

```
1 Matriz_Similaridad_Coincidencias(Datos_Categoricos_Multiples)
```

3.5.4. Mas coeficientes de similaridad:

Coeficiente	Valores	Cuando se aplica sobre binarias . . .
$SC_1 \quad \frac{\alpha}{p}$	$(0, 1)$	S_4
$SC_2 \quad \frac{\alpha}{p-\alpha}$	$(0, \infty)$	
$SC_3 \quad \frac{\alpha-(p-\alpha)}{p}$	$(-1, 1)$	S_9
$SC_4 \quad \frac{\alpha}{\alpha+2(p-\alpha)}$	$(0, 1)$	S_6

4. DISTANCIAS CON VARIABLES DE TIPO MIXTO:

Sean $X = (X_1, \dots, X_p)$ una matriz de datos de tipo mixto tal que:

X_1, \dots, X_{p_1} son variables cuantitativas

$X_{p_1+1}, \dots, X_{p_1+p_2}$ son variables categoricas binarias

$X_{p_1+p_2+1}, \dots, X_{p_1+p_2+p_3}$ son variables categoricas multiples (no binarias).

Donde: $p = p_1 + p_2 + p_3$

4.1. Coeficiente de similitud de Gower:

Coeficiente de similitud de Gower:

El coeficiente de similitud de Gower entre los elementos i y j respecto de las variables X_1, \dots, X_p es:

$$S(i, j)_{Gower} = \frac{\sum_{k=1}^{p_1} \left(1 - \frac{|x_{ik} - x_{jk}|}{G_k} \right) + a_{ij} + \alpha_{ij}}{p_1 + (p_2 - d_{ij}) + p_3}$$

Donde:

p_1 es el numero de variables cuantitativas

p_2 es el numero de variables categoricas binarias

p_3 es el numero de variables categoricas multiples (no binarias)

G_k es el rango de la k -esima variable cuantitativa ($G_k = \max(X_k) - \min(X_k)$)

a_{ij} es el numero de variables binarias (hay p_2) para las que las respuesta es 1 en ambos individuos i y j

d_{ij} es el numero de variables binarias (hay p_2) para las que las respuesta es 0 en ambos individuos i y j

α_{ij} es el numero de coincidencias entre las variables categoricas multiples no binarias (hay p_3) para los individuos i y j

4.1.1. Distancia de Gower:

Distancia de Gower:

La distancia de Gower se obtiene como:

$$\delta(i, j)_{Gower} = \sqrt{1 - S(i, j)_{Gower}}$$

4.1.2. Propiedades:

El coeficiente de similaridad de Gower es la suma de diferentes coeficientes apropiados para cada tipo de variables.

Si solo tenemos variables cuantitativas, la distancia que se obtiene es:

$$\frac{1}{p} \sum_{k=1}^p \left(1 - \frac{|x_{ik} - x_{jk}|}{G_k} \right)$$

Si solo tenemos variables categoricas binarias, el coeficiente de similaridad de Gower coincide con el de Jaccard.

Si solo tenemos variables categoricas múltiples no binarias, el coeficiente de Gower coincide con el coeficiente de coincidencias.

Con esta idea pueden construirse otros coeficientes de similaridad para datos de tipo mixto. Algunas recomendaciones para ello son las siguientes:

Si se quiere que el coeficiente resultante tenga la propiedad euclídea, todos los coeficientes que se combinen deben tenerla.

Para variables cuantitativas, deben usarse coeficientes que dividan cada comparación por un factor de normalización antes de sumar.

Para variables binarias y cualitativas serán preferibles aquellos coeficientes que tomen valores en $[0,1]$ para evitar rescalar las similaridades antes de sumar

4.1.3. Aplicación en R: Coeficiente de Gower

Programamos el coeficiente de Gower:

```
1 Similaridad_Gower <- function(i,j, Matriz_Datos_Mixtos, p1,
2   p2, p3){
3   X=as.matrix(Matriz_Datos_Mixtos) #tienen que estar las
4     variables ordenadas del siguiente modo: las p1 primeras
5     son cuantitativas, las p2 siguientes son binarias, las p3
6     siguientes son categoricas multiples (no binarias). De
7     modo que p=p1+p2+p3
8
9   #####
10  G<- function(k, X){
11
12    G =max(X[,k])-min(X[,k])
13
14    return(G)
15  }
16  #####
17
18  G_vector<-rep(0, p1)
19
20  for(r in 1:p1){
21    G_vector[r]=G(r, X)
22  }
23
24  Matriz_Datos_Binarios = X[, (p1+1):(p1+p2)]
25
26  a= Matriz_Datos_Binarios %*% t(Matriz_Datos_Binarios)
27
28  unos<- rep(1, dim(Matriz_Datos_Binarios)[2])
29
30  Matriz_Unos<- matrix( rep(unos, dim(Matriz_Datos_Binarios)[1
31    ]),
32      ncol=dim(Matriz_Datos_Binarios)[2])
33
34  d= (Matriz_Unos - Matriz_Datos_Binarios)%*%t(Matriz_Unos -
35    Matriz_Datos_Binarios)
36
37  Matriz_Datos_Categoricos_Multiples = X[, (p1+p2+1):(p1+p2+p
38    3)]
39
40  Matriz_Datos_Cuantitativos = X[, 1:p1]
```

```

35
36 Similaridad_Gower = ( sum( 1 - abs(Matriz_Datos_Cuantitativos
    [i,] - Matriz_Datos_Cuantitativos[j,])/G_vector ) + a[i,j]
    + alpha(i,j,Matriz_Datos_Categoricos_Multiples) ) / (p1+p2
    - d[i,j] + p3)
37
38 return(Similaridad_Gower)
39 }

```

```

1 Similaridad_Gower(1,3, Datos_Mixtos, p1=4, p2=3, p3=3)

```

```
[1] 0.5165602
```

```

1 Matriz_Similaridad_Gower <- function( Matriz_Datos_Mixtos, p1,
    p2, p3 ){
2
3     Matriz_Datos_Mixtos=as.matrix(Matriz_Datos_Mixtos)
4
5     M<-matrix(NA, ncol =dim(Matriz_Datos_Mixtos)[1] , nrow=dim(
        Matriz_Datos_Mixtos)[1] )
6
7     for(i in 1:dim(Matriz_Datos_Mixtos)[1] ){
8         for(j in 1:dim(Matriz_Datos_Mixtos)[1]){
9
10            M[i,j]=Similaridad_Gower(i,j, Matriz_Datos_Mixtos, p1, p2,
                p3)
11
12            }
13        }
14    return(M)
15 }

```

```
1 Matriz_Similaridad_Gower(Datos_Mixtos, p1=4, p2=3, p3=3)
```

	[,1]	[,2]	[,3]	[,4]	[,5]	[,6]	[,7]	[,8]	[,9]	[,10]	[,11]
[1,]	1.0000000	0.5654928	0.5165602	0.4022478	0.6565382	0.5125703	0.2935260	0.3063523	0.5264566	0.5868549	0.4481669
[2,]	0.5654928	1.0000000	0.3303969	0.5859647	0.5928171	0.6328963	0.3388553	0.3216607	0.3230980	0.5301022	0.3604663
[3,]	0.5165602	0.3303969	1.0000000	0.3911722	0.5015897	0.4316305	0.4797372	0.3635812	0.4985116	0.5921263	0.3277794
[4,]	0.4022478	0.5859647	0.3911722	1.0000000	0.6069985	0.6871983	0.4754642	0.5024760	0.4236752	0.5292688	0.6322549
[5,]	0.6565382	0.5928171	0.5015897	0.6069985	1.0000000	0.5556749	0.4508424	0.4317373	0.5902273	0.8460574	0.4590014
[6,]	0.5125703	0.6328963	0.4316305	0.6871983	0.5556749	1.0000000	0.5670997	0.2499051	0.4328212	0.4569248	0.4930530
[7,]	0.2935260	0.3388553	0.4797372	0.4754642	0.4508424	0.5670997	1.0000000	0.3503660	0.4664281	0.4850596	0.5202198
[8,]	0.3063523	0.3216607	0.3635812	0.5024760	0.4317373	0.2499051	0.3503660	1.0000000	0.5576532	0.4635663	0.5710651
[9,]	0.5264566	0.3230980	0.4985116	0.4236752	0.5902273	0.4328212	0.4664281	0.5576532	1.0000000	0.7121911	0.4168814
[10,]	0.5868549	0.5301022	0.5921263	0.5292688	0.8460574	0.4569248	0.4850596	0.4635663	0.7121911	1.0000000	0.3488899
[11,]	0.4481669	0.3604663	0.3277794	0.6322549	0.4590014	0.4930530	0.5202198	0.5710651	0.4168814	0.3488899	1.0000000
[12,]	0.3084297	0.4739225	0.5005427	0.6338809	0.3949563	0.4751561	0.5518909	0.4587867	0.3803721	0.4635851	0.5263597
[13,]	0.5355538	0.4939358	0.3721983	0.4236313	0.4447447	0.3951694	0.3437900	0.4758841	0.4375915	0.3747110	0.4926987
[14,]	0.4954432	0.5796797	0.5186107	0.5809913	0.5031109	0.8079241	0.4709507	0.3170245	0.4400840	0.4154410	0.4239709
[15,]	0.4196521	0.5699125	0.3110001	0.6653853	0.4012674	0.5981570	0.3626549	0.4541431	0.3605311	0.2998350	0.6759610
[16,]	0.5825527	0.4547046	0.2532723	0.6112008	0.6723344	0.4641745	0.4170948	0.5397802	0.4604751	0.5401412	0.6441637
[17,]	0.5301965	0.3169008	0.3859776	0.6051784	0.6424607	0.3550158	0.2193040	0.5524408	0.6168983	0.5343449	0.6063757
[18,]	0.4503915	0.5523242	0.4729275	0.6241128	0.5440019	0.8128936	0.4711159	0.3370115	0.4292262	0.4222220	0.4690993
[19,]	0.4757416	0.2733369	0.5096197	0.3423419	0.4717718	0.3047944	0.4422621	0.4401317	0.6427924	0.5466831	0.5640501
[20,]	0.2557322	0.4048409	0.4715115	0.3856562	0.2305699	0.3107696	0.3137202	0.4097992	0.3419218	0.2809335	0.3527430

En este caso pasamos de similaridad a distancia usando la transformacion:

$$\delta(i, j)_{Gower} = \sqrt{1 - S(i, j)_{Gower}}$$

```
1 Dist_Gower <- function(i, j, Matriz_Datos_Mixtos , p1, p2, p3)
  {
2
3 Dist_Gower <- sqrt( 1 - Similaridad_Gower(i, j, Matriz_Datos_
  Mixtos , p1, p2, p3) )
4
5 return(Dist_Gower)
6 }
```

```
1 Dist_Gower(1,3, Datos_Mixtos, p1=4, p2=3, p3=3)
```

```
[1] 0.6952984
```

```

1  Matriz_Dist_Gower <- function( Matriz_Datos_Mixtos, p1, p2, p3
    ){
2
3      Matriz_Datos_Mixtos=as.matrix(Matriz_Datos_Mixtos)
4
5      M<-matrix(NA, ncol =dim(Matriz_Datos_Mixtos)[1] , nrow=dim(
        Matriz_Datos_Mixtos)[1] )
6
7      for(i in 1:dim(Matriz_Datos_Mixtos)[1] ){
8          for(j in 1:dim(Matriz_Datos_Mixtos)[1]){
9
10             M[i,j]=Dist_Gower(i,j, Matriz_Datos_Mixtos, p1, p2, p3)
11
12         }
13     }
14     return(M)
15 }

```

```

1  Matriz_Dist_Gower(Datos_Mixtos, p1=4, p2=3, p3=3)

```

	[,1]	[,2]	[,3]	[,4]	[,5]	[,6]	[,7]	[,8]	[,9]	[,10]	[,11]
[1,]	0.0000000	0.6591716	0.6952984	0.7731444	0.5860561	0.6981616	0.8405201	0.8328551	0.6881449	0.6427636	0.7428547
[2,]	0.6591716	0.0000000	0.8182928	0.6434557	0.6381088	0.6058908	0.8131080	0.8236136	0.8227405	0.6854909	0.7997085
[3,]	0.6952984	0.8182928	0.0000000	0.7802742	0.7059818	0.7539029	0.7212925	0.7977586	0.7081584	0.6386499	0.8198906
[4,]	0.7731444	0.6434557	0.7802742	0.0000000	0.6268983	0.5592868	0.7242484	0.7053538	0.7591606	0.6860985	0.6064199
[5,]	0.5860561	0.6381088	0.7059818	0.6268983	0.0000000	0.6665771	0.7410517	0.7538320	0.6401349	0.3923553	0.7355261
[6,]	0.6981616	0.6058908	0.7539029	0.5592868	0.6665771	0.0000000	0.6579516	0.8660802	0.7531128	0.7369364	0.7120021
[7,]	0.8405201	0.8131080	0.7212925	0.7242484	0.7410517	0.6579516	0.0000000	0.8059988	0.7304600	0.7175935	0.6926617
[8,]	0.8328551	0.8236136	0.7977586	0.7053538	0.7538320	0.8660802	0.8059988	0.0000000	0.6650916	0.7324163	0.6549312
[9,]	0.6881449	0.8227405	0.7081584	0.7591606	0.6401349	0.7531128	0.7304600	0.6650916	0.0000000	0.5364782	0.7636220
[10,]	0.6427636	0.6854909	0.6386499	0.6860985	0.3923553	0.7369364	0.7175935	0.7324163	0.5364782	0.0000000	0.8069139
[11,]	0.7428547	0.7997085	0.8198906	0.6064199	0.7355261	0.7120021	0.6926617	0.6549312	0.7636220	0.8069139	0.0000000
[12,]	0.8316070	0.7253120	0.7067229	0.6050777	0.7778455	0.7244611	0.6694095	0.7356720	0.7871645	0.7324035	0.6882153
[13,]	0.6815029	0.7113819	0.7923394	0.7591895	0.7451546	0.7777086	0.8100679	0.7239585	0.7499390	0.7907522	0.7122509
[14,]	0.7103216	0.6483212	0.6938223	0.6473088	0.7049036	0.4382646	0.7273578	0.8264233	0.7482754	0.7645646	0.7589658
[15,]	0.7618057	0.6558105	0.8300602	0.5784589	0.7737781	0.6339109	0.7983389	0.7388213	0.7996680	0.8367586	0.5692443
[16,]	0.6461016	0.7384412	0.8641341	0.6235376	0.5724208	0.7320010	0.7634823	0.6783950	0.7345236	0.6781289	0.5965202
[17,]	0.6854221	0.8264981	0.7835958	0.6283483	0.5979459	0.8031091	0.8835700	0.6689987	0.6189521	0.6823892	0.6273949
[18,]	0.7413559	0.6690858	0.7259976	0.6130964	0.6752763	0.4325579	0.7272442	0.8142411	0.7554957	0.7601171	0.7286293
[19,]	0.7240569	0.8524454	0.7002716	0.8109612	0.7267931	0.8337899	0.7468185	0.7482435	0.5976684	0.6732881	0.6602650
[20,]	0.8627095	0.7714656	0.7269722	0.7838009	0.8771717	0.8301990	0.8284201	0.7682453	0.8112202	0.8479779	0.8045229

4.2. Coeficiente de similitud de Gower-Mahalanobis:

Coeficiente de similitud de Gower-Mahalanobis:

El coeficiente de similitud de Gower-Mahalanobis entre los elementos i y j respecto de las variables X_1, \dots, X_p es:

$$S(i, j)_{Gower-Maha} = \frac{\left(1 - \frac{\delta(i, j)_{Maha}}{\max(D_{Maha})}\right) + a_{ij} + \alpha_{ij}}{(p_2 - d_{ij}) + p_3}$$

Donde:

p_2 es el numero de variables categoricas binarias

p_3 es el numero de variables categoricas multiples (no binarias)

$\delta(i, j)_{Maha}$ es la distancia de Mahalanobis entre los individuos respecto de las p_1 variables cuantitativas

$\max(D_{Maha})$ es el maximo valor de la matriz de distancias de Mahalanobis $\delta(i, j)_{Maha}$ entre los individuos respecto de las p_1 variables cuantitativas.

a_{ij} es el numero de variables binarias (hay p_2) para las que las respuesta es 1 en ambos individuos i y j

d_{ij} es el numero de variables binarias (hay p_2) para las que las respuesta es 0 en ambos individuos i y j

α_{ij} es el numero de coincidencias entre las variables categoricas multiples no binarias (hay p_3) para los individuos i y j

4.2.1. Distancia de Gower-Mahalanobis:

Distancia de Gower-Mahalanobis:

La distancia de Gower-Mahalanobis:

$$\delta(i, j)_{Gower-Maha} = \sqrt{S(i, i)_{Gower-Maha} + S(j, j)_{Gower-Maha} - 2 \cdot S(i, j)_{Gower-Maha}}$$

4.2.2. Aplicación en R: Coeficiente de similitud de Gower-Mahalanobis

```
1 Similaridad_Gower_Mahalanobis <- function(i,j, Matriz_Datos_
  Mixtos, p1, p2, p3){
2
3   X=as.matrix(Matriz_Datos_Mixtos)
4   #tienen que estar las variables ordenadas del siguiente modo:
      las p1 primeras son cuantitativas, las p2 siguientes son
      binarias, las p3 siguientes son categoricas multiples (no
      binarias). De modo que p=p1+p2+p3
5
6   #####
7   G<- function(k, X){
8
9     G=max(X[,k])-min(X[,k])
10
11    return(G)
12  }
13  #####
14
15  G_vector<-rep(0, p1)
16
17  for(r in 1:p1){
18    G_vector[r]=G(r, X)
19  }
20
21  Matriz_Datos_Binarios = X[, (p1+1):(p2+p1)]
22
23  a= Matriz_Datos_Binarios %*% t(Matriz_Datos_Binarios)
24
25  unos<- rep(1, dim(Matriz_Datos_Binarios)[2])
26
27  Matriz_Unos<- matrix( rep(unos, dim(Matriz_Datos_Binarios)[1
    ]),
28                        ncol=dim(Matriz_Datos_Binarios)[2])
29
30  d= (Matriz_Unos - Matriz_Datos_Binarios)%*%t(Matriz_Unos -
31        Matriz_Datos_Binarios)
32
33  Matriz_Datos_Categoricos_Multiples = X[, (p1+p2+1):(p1+p2+p
34        3)]
35
36  Matriz_Datos_Cuantitativos = X[, 1:p1]
```

```

37     max_maha=max(Matriz_Datos_Cuantitativos)
38
39     Similaridad_Gower_Mahalanobis = ( 1 - Dist_Mahalanobis(i,j,
    Matriz_Datos_Cuantitativos)/max_maha + a[i,j] + alpha(i,j,
    Matriz_Datos_Categoricos_Multiples) ) / ( p2- d[i,j] + p3
    )
40
41     return(Similaridad_Gower_Mahalanobis)
42 }

```

```

1 Similaridad_Gower_Mahalanobis(1,2, Datos_Mixtos, p1=4, p2=3, p
    3=3)

```

```

1 Matriz_Similaridad_Gower_Mahalanobis <- function( Matriz_Datos
    _Mixtos, p1, p2, p3 ){
2
3     Matriz_Datos_Mixtos=as.matrix(Matriz_Datos_Mixtos)
4
5     M<-matrix(NA, ncol =dim(Matriz_Datos_Mixtos)[1] , nrow=dim(
    Matriz_Datos_Mixtos)[1] )
6
7     for(i in 1:dim(Matriz_Datos_Mixtos)[1] ){
8         for(j in 1:dim(Matriz_Datos_Mixtos)[1]){
9
10            M[i,j]=Similaridad_Gower_Mahalanobis(i,j, Matriz_Datos_
    Mixtos, p1, p2, p3)
11
12        }
13    }
14    return(M)
15 }

```

```

1 Matriz_Similaridad_Gower_Mahalanobis(Datos_Mixtos, p1=4, p2=3,
    p3=3)

```

En este caso pasamos de similaridad a distancia usando la transformacion:

$$\delta(i, j)_{Gower-Maha} = \sqrt{S(i, i)_{Gower-Maha} + S(j, j)_{Gower-Maha} - 2 \cdot S(i, j)_{Gower-Maha}}$$

```
1 Dist_Gower_Mahalanobis <- function(i, j, Matriz_Datos_Mixtos ,  
  p1, p2, p3) {  
2  
3 Dist_Gower_Mahalanobis <- sqrt( Similaridad_Gower_Mahalanobis(  
  i, i, Matriz_Datos_Mixtos , p1, p2, p3) + Similaridad_Gower  
  _Mahalanobis(j, j, Matriz_Datos_Mixtos , p1, p2, p3) -2*  
  Similaridad_Gower_Mahalanobis(i, j, Matriz_Datos_Mixtos , p  
  1, p2, p3))  
4  
5 return(Dist_Gower_Mahalanobis)  
6 }
```

```
1 Dist_Gower_Mahalanobis(1,2, Datos_Mixtos, p1=4, p2=3, p3=3)
```

```
1 Matriz_Dist_Gower_Mahalanobis <- function( Matriz_Datos_Mixtos  
  , p1, p2, p3 ){  
2  
3 Matriz_Datos_Mixtos=as.matrix(Matriz_Datos_Mixtos)  
4  
5 M<-matrix(NA, ncol =dim(Matriz_Datos_Mixtos)[1] , nrow=dim(  
  Matriz_Datos_Mixtos)[1] )  
6  
7 for(i in 1:dim(Matriz_Datos_Mixtos)[1] ){  
8   for(j in 1:dim(Matriz_Datos_Mixtos)[1]){  
9  
10 M[i,j]=Dist_Gower_Mahalanobis(i,j, Matriz_Datos_Mixtos, p1,  
  p2, p3)  
11  
12   }  
13 }  
14 return(M)  
15 }
```

```
1 Matriz_Dist_Gower_Mahalanobis(Datos_Mixtos, p1=4, p2=3, p3=3)
```